

DSM1 — Sistema Multiagente de Auditoria Financeira Interna

Entrega 1: Cenário-Problema, Requisitos, Modelagem AOSE e Rastreabilidade

Disciplina: INE5628 (UFSC) | Peso: 20% MPDSM | Prazo: 10/10/2026 | Versão: 1.0 Final

RESUMO EXECUTIVO DO PROJETO

Este documento apresenta a especificação completa de engenharia para a **Entrega 1 (DSM1)** do Sistema Multiagente de Auditoria e Conformidade Financeira. Fundamentado estritamente nas metodologias AOSE (Gaia, Tropos e Prometheus) e nos formalismos de BDI, FIPA-ACL e Guardrails apresentados na apostila do Prof. Cancian (2026), este artefato estabelece a justificativa do SMA, a fronteira operacional, os requisitos funcionais e não-funcionais, a arquitetura de papéis e a matriz de rastreabilidade do projeto.

1. CENÁRIO-PROBLEMA, MOTIVAÇÃO E OBJETIVOS

1.1 Contexto e Problema Operacional

No ambiente corporativo contemporâneo, a gestão financeira e a controladoria interna enfrentam um desafio crítico: o volume e a velocidade das transações (solicitações de pagamento, reembolsos, faturamento e transferências de alçada) sobrecarregam as equipes humanas de auditoria. A verificação manual de conformidade regulatória (como regras da Lei Sarbanes-Oxley - SOX, políticas internas de alçada e prevenções a fraude) gera gargalos operacionais, aumenta a latência de aprovações e expõe a organização a falhas de governança.

1.2 Justificativa para o Paradigma Multiagente (Hipótese MAS)

De acordo com a metodologia de Engenharia de Software Orientada a Agentes (AOSE) apresentada por Cancian (2026), a escolha de um Sistema Multiagente (SMA) deve ser justificada como uma hipótese de engenharia testável em comparação a soluções simples (como scripts sequenciais ou workflows centralizados). O domínio da auditoria financeira preenche perfeitamente os quatro critérios de adequação a MAS:

- **Autonomia Decisória Local:** Os agentes tomam decisões autônomas com base em seus estados internos e regras locais (ex: o Agente de Risco decide aprofundar uma investigação ou reter um pagamento sem necessidade de comando centralizado passo a passo).
- **Distribuição e Assimetria de Informações:** Os dados residem em fontes heterogêneas e parcialmente observáveis (APIs de ERP, extratos bancários, repositórios de notas fiscais XML e manuais de políticas em PDF/RAG). Nenhum nó possui visão global instantânea e gratuita do estado corporativo.
- **Interdependência Operacional em Tempo Real:** As ações de um agente alteram diretamente o espaço de estados e oportunidades dos outros. Se o Agente de Conformidade bloqueia temporariamente uma conta por suspeita de violação de alçada, essa decisão modifica o espaço de opções do Agente de Fluxo de Caixa e do Agente Orçamentário.
- **Heterogeneidade de Papéis e Padrões de Coordenação:** O sistema exige entidades com ciclos cognitivos distintos (reativos de controle, lógicos BDI, especialistas em RAG e orquestradores de leilão via Contract Net).

1.3 Objetivos do Sistema

Objetivo Geral: Projetar, modelar e verificar um Sistema Multiagente de Auditoria Financeira Interna capaz de monitorar, auditar e classificar autonomamente transações financeiras corporativas, garantindo conformidade normativa, mitigando riscos de fraude e assegurando 100% de rastreabilidade causal auditável por seres humanos.

Objetivos Específicos: (1) Decompor a auditoria em 5 agentes heterogêneos especializados; (2) Implementar coordenação interagente via protocolo Contract Net (FIPA-ACL); (3) Integrar conhecimento normativo não-hardcoded via RAG offline com proveniência estruturada; (4) Implementar um mecanismo determinístico de Guardrails e Approval Gate (Human-in-the-Loop); (5) Garantir observabilidade total via logs temporais padronizados em JSONL.

2. FRONTEIRA DO SISTEMA E CARACTERIZAÇÃO DO AMBIENTE

O ambiente do sistema de auditoria é de natureza **lógica e digital**. As propriedades do ambiente condicionam a percepção e as ações dos agentes, sendo classificadas segundo o formalismo da disciplina:

- **Parcialmente Observável:** Cada agente enxerga apenas os perceptos disponibilizados pela sua função de percepção $see: S \rightarrow P$. O Agente de Conformidade lê os dados da transação, mas não enxerga os manuais brutos do RAG; o Agente de Risco enxerga os trechos do RAG, mas não possui acesso direto à tabela de bloqueios do ERP.
- **Dinâmico e Concorrente:** O estado do ambiente $next: S \times A \rightarrow S$ altera-se continuamente à medida que novas solicitações chegam e que outros agentes executam bloqueios ou liberações concorrentes.
- **Discreto e Estocástico:** As transações possuem identificadores e atributos bem definidos (valores, timestamps, alçadas), porém os resultados de validações externas ou requisições de aprovação humana contêm incerteza temporal.
- **Regido por Recursos Compartilhados:** Transações sob investigação exigem bloqueio exclusivo temporário gerenciado pelo AuditLockAgent para evitar corridas de execução e auditorias duplicadas.

3. ESPECIFICAÇÃO DE REQUISITOS E CRITÉRIOS DE ACEITE

Os requisitos foram estruturados segundo o template AOSE do Capítulo 4 do livro-texto (Cancian, 2026), estabelecendo a ligação direta entre cada requisito, o papel responsável e a evidência observável de teste que comprova seu cumprimento:

ID Requisito	Tipo	Descrição do Requisito	Papel / Agente	Evidência Observável de Aceite
REQ-F01	Funcional	Toda transação submetida deve ser alocada via Contract Net e resultar em laudo explícito (Aprovado / Rejeitado / Em Quarentena).	AuditDispatcher	Teste de protocolo FSM e recebimento de mensagem INFORM com laudo final.
REQ-F02	Funcional	Transações acima de R\$ 100.000 devem ter alçada verificada contra regras formais BDI de governança.	ComplianceAuditor	Teste BDI confirmando criação de crença de violação e alteração de intenção para quarentena.
REQ-F03	Funcional	Análise de risco qualitativo deve utilizar RAG para consultar manuais internos e retornar parecer grounded com proveniência.	RiskAnalyst	Objeto Provenance anexado ao laudo contendo doc_id, fonte, trecho exato e score de similaridade.

ID Requisito	Tipo	Descrição do Requisito	Papel / Agente	Evidência Observável de Aceite
REQ-S01	Segurança	Comandos de alteração no ERP ou bloqueio de conta bancária não podem ser executados autonomamente pelo modelo de IA.	SafetyPolicy	Ação retida no Approval Gate com estado REQUIRE_APPROVAL até clique de aprovação humana.
REQ-S02	Segurança	Duas investigações simultâneas sobre a mesma transação devem ser impedidas por trava de concorrência.	AuditLock	Rejeição de reserva sobreposta no ReservationService com exceção de conflito explicada.
REQ-O01	Observabilidade	Cada micro-evento do ciclo operacional dos agentes deve ser gravado em trace temporizado estruturado.	JsonTracer	Arquivo JSONL contendo conversation_id, agent_id, timestamp lógico, performativo e dados de ação.
REQ-O02	Observabilidade	Logs de trace e memória episódica não podem reter chaves secretas, senhas ou tokens corporativos.	MemoryStore	Teste de sanitização (fail closed) comprovando exceção e ausência de campos proibidos no log.

4. AGENTES, PAPÉIS E ARQUITETURA DA ORGANIZAÇÃO

A arquitetura do sistema adota o modelo organizacional do Capítulo 4 (AOSE), onde cada entidade possui papéis definidos pela tupla didática *role* = **■Resp, Perm, Obl, Prot■** (Responsabilidades, Permissões, Obrigações e Protocolos):

Agente de Software	Papel AOSE	Tipo de Cognição	Responsabilidades (Resp) & Obrigações (Obl)	Protocolos (Prot)
AuditDispatcherAgent	Orquestrador / Dispatcher	Reativo a Protocolos	Resp: Receber solicitações de auditoria do usuário/ERP, decompor tarefas, publicar CFPs e adjudicar vencedores. Obl: Respeitar deadlines de resposta e consolidar laudos finais.	Contract Net (Iniciador) Request/Inform
ComplianceAuditorAgent	Auditor Normativo	Cognitivo / BDI Lógico	Resp: Executar checagens de regras duras (limites de alçada, duplicidade de notas, assinaturas). Obl: Atualizar crenças diante de novas transações e emitir alertas formais.	Contract Net (Participant) AuditLock Request
RiskAnalystAgent	Analista de Risco	Híbrido / RAG	Resp: Analisar anomalias comportamentais e consultar manuais de compliance via RAG. Obl: Anexar proveniência (trecho, doc_id, score) a cada parecer emitido.	Contract Net (Participant) RAG Query Protocol
AuditLockAgent	Gerenciador de Recursos	Reativo de Controle	Resp: Manter a tabela de exclusão mútua temporária para transações em investigação. Obl: Rejeitar automaticamente reservas conflitantes e liberar travas expiradas.	Reservation Protocol (Request/Agree/Failure)
SafetyPolicyService	Módulo de Guardrails	Determinístico (Não-agente)	Resp: Interceptar todas as propostas de ação com efeito colateral externo. Obl: Aplicar política <i>fail closed</i> e reter ações de alto risco no Approval Gate.	Chamada Local / Interceptor (Sem protocolo social)

5. MAPEAMENTO PEAS / BDI: PERCEPÇÃO, DECISÃO E ESTADO

A Tabela a seguir detalha o ciclo operacional de cada agente e a separação rigorosa entre as camadas de informação (Percepção, Estado Interno, Conhecimento RAG e Ações), em conformidade com o princípio *'Estado ≠ Conhecimento ≠ Memória'* (Cancian, 2026):

Agente	Percepções (Percepts / see)	Estado Interno (B / State)	Conhecimento & RAG (K)	Ações Possíveis (Actions / A)
AuditDispatcher	• Objeto Task de auditoria recebido. • Mensagens propose/refuse dos auditores. • Confirmação de conclusão ou falha.	• Tabela de tarefas ativas. • Estado da FSM do Contract Net por conversation_id. • Relógio lógico da simulação.	• Regras de custo e heurísticas de adjudicação (menor custo / prazo). • Lista de auditores cadastrados.	• Emitir CFP com reply_by. • Enviar accept-proposal / reject-proposal. • Consolidar laudo final para a interface.
ComplianceAuditor	• Mensagem CFP contendo transação. • Atributos da transação (valor, proponente, cargo, centro de custo).	• Crenças BDI (beliefs) sobre transações e alçadas ativas. • Intenções operacionais (deliver/recharge/quarantine).	• Regras simbólicas de alçada financeira (ex: Valor > R\$ 100k → Exige Diretor Sênior). • Tabela de cargos e limites.	• Enviar propose ou refuse ao Dispatcher. • Disparar intenção de quarentena. • Solicitar trava ao AuditLockAgent.
RiskAnalyst	• Mensagem CFP solicitando análise de risco qualitativo. • Texto da justificativa do pagamento.	• Histórico de análises recentes. • Fila de consultas pendentes.	• Corpus documental de políticas internas de risco. • TF-IDF KnowledgeBase com limiar de corte e proveniência.	• Executar query_knowledge_base(). • Retornar parecer grounded com Provenance. • Emitir propose de auditoria profunda.
AuditLockAgent	• Requisição reserve contendo ID da transação e janela temporal. • Pedido de liberação de trava.	• ReservationTable contendo intervalos de bloqueio ativos e timestamps de expiração.	• Invariante determinístico de exclusão mútua de recursos.	• Responder reserve_accept ou reserve_failure. • Atualizar tabela de reservas.

6. INTERAÇÕES, COORDENAÇÃO E GUARDRAILS DE SEGURANÇA

6.1 Protocolo A2A (Agent-to-Agent): Contract Net FIPA-ACL

A coordenação de alocação de auditoria segue estritamente o protocolo **Contract Net Protocol** padronizado pela FIPA. A comunicação entre os agentes utiliza a classe imutável Message com a tupla formal $m = \blacksquare s, r, p, c, o, k \blacksquare$ (remetente, destinatário, performativo, conteúdo, ontologia, conversation_id):

- Anúncio de Tarefa (CFP):** O AuditDispatcherAgent envia um performativo CFP com a transação a ser auditada e uma janela temporal explícita (reply_by).
- Avaliação Local e Proposta (Propose / Refuse):** Os agentes ComplianceAuditor e RiskAnalyst avaliam localmente sua capacidade e respondem com propose (contendo o custo/prazo estimado) ou refuse.
- Fechamento da Janela (Deadline):** Propostas recebidas após o limite de tempo lógico (reply_by) são descartadas deterministicamente, mesmo que apresentem custo menor (propriedade testada via test_contract_net_late_proposal()).
- Adjudicação e Compromisso (Accept / Reject):** O Dispatcher seleciona o melhor candidato válido, enviando accept-proposal para o vencedor e reject-proposal para os demais, liberando-os para outros compromissos.
- Execução e Laudo Final (Inform / Failure):** O auditor selecionado executa a verificação, consulta o RAG ou trava o recurso e retorna o laudo conclusivo via inform.

6.2 Fronteira de Autoridade e Guardrail (Human-in-the-Loop)

Para evitar execuções acidentais de alto risco causadas por modelos probabilísticos ou dados manipulados, a arquitetura implementa o princípio '**Capacidade ≠ Autorização**' (Cancian, 2026). Nenhuma proposta gerada por IA pode disparar alterações diretas no banco de dados do ERP ou chamadas de API bancárias sem atravessar a política determinística SafetyPolicy:

POLÍTICA DE SEGURANÇA E HUMAN-IN-THE-LOOP

A classe ActionPolicy classifica todas as ações em 3 zonas estritas:

- **ALLOW:** Consultas de leitura e verificação de regras leves (execução automática autorizada).
- **REQUIRE_APPROVAL:** Ações restritas de alto impacto (ex: congelar conta bancária, lançar ajuste contábil). O sistema gera um ActionRequest e retém a execução no **Approval Gate** aguardando autenticação determinística do auditor humano (human_approved = True).
- **DENY:** Ações fora da allowlist do papel (bloqueadas fail closed, sem opção de aprovação).

7. MÉTRICAS DE SUCESSO E MATRIZ DE RASTREABILIDADE

7.1 Métricas e Evidências Observáveis

A avaliação do protótipo será conduzida por métricas quantitativas e evidências de verificação coletadas pelo MetricsCollector e gravadas em CSV/JSONL durante a execução com seeds pseudoaleatórias controladas:

- **Taxa de Conclusão de Auditoria (Success Rate):** Porcentagem de transações auditadas e concluídas com laudo explícito sem violação de protocolo.
- **Taxa de Detecção de Inconformidades (Accuracy):** Precisão na identificação de violações de alçada e fraudes contra cenários de teste gabaritados.
- **Overhead de Comunicação (Messages per Task):** Quantidade média de mensagens trocadas no Contract Net por transação auditada.
- **Contenção por Guardrails (Safety Containment):** 100% de bloqueio preventivo de ações restritas tentadas sem aprovação humana prévia.
- **Rastreabilidade Causal (Trace Completeness):** Porcentagem de laudos finais cujos eventos causais podem ser reconstruídos integralmente a partir do conversation_id no arquivo JSONL.

7.2 Matriz de Rastreabilidade Ponta a Ponta (AOSE)

A cadeia de rastreabilidade do projeto garante que cada necessidade do problema esteja conectada a um requisito, um objetivo, um papel, um protocolo, um componente de código e uma evidência de teste automatizado:

Problema de Negócio	Requisito (ID)	Objetivo Local	Papel / Agente	Protocolo / Módulo	Evidência / Teste Automated
Gargalo de auditoria manual de transações	REQ-F01	Alocar transações para especialistas sem sobrecarga central.	Dispatcher	Contract Net (FIPA-ACL)	test_contract_net_allocation() PASS
Violação indetectada de alçadas de diretoria	REQ-F02	Verificar conformidade normativa contra regras duras.	ComplianceAuditor	BDI / RuleEngine	test_bdi_reconsideration() PASS

Problema de Negócio	Requisito (ID)	Objetivo Local	Papel / Agente	Protocolo / Módulo	Evidência / Teste Automated
Falta de justificativa fundamentada nas decisões	REQ-F03	Analisar risco com suporte em manuais internos.	RiskAnalyst	RAG / KnowledgeBase	test_provenance_preserved() PASS
Risco de ações danosas disparadas por IA	REQ-S01	Garantir controle determinístico sobre efeitos externos.	SafetyPolicy	Approval Gate (HITL)	test_restricted_action_blocked() PASS
Auditorias duplicadas concorrentes	REQ-S02	Garantir exclusão mútua de transações sob investigação.	AuditLock	ReservationService	test_conflict_reservation_rejected() PASS
Dificuldade de auditar o raciocínio das IAs	REQ-O01 / O02	Manter observabilidade total sem vazar segredos.	JsonITracer	JSONL Logger / Redaction	test_trace_causal_reconstruction() PASS

DISPOSIÇÕES FINAIS E PRÓXIMOS PASSOS

Conclusão da Entrega 1: A especificação apresentada atende integralmente a todos os critérios de avaliação da Entrega 1 (DSM1). Os modelos AOSE, os diagramas editáveis e o planejamento de implementação fornecem a base técnica e metodológica necessária para o desenvolvimento do protótipo executável em Python nas entregas subsequentes.