UNIVERSIDADE FEDERAL DE SANTA CATARINA
Centro Tecnológico · Departamento de Informática e Estatística
INE5628 — Sistemas Multiagentes · Prof. Dr. Rafael Luiz Cancian

Sistema Multiagente de Controladoria

Relatório técnico da entrega final (DSM4)

Arquitetura, protocolos, segurança, cognição, experimentação e limitações

Danrley Moreira Ribeiro (23102664)
Jiliard Mai Peifer (23103129)

Versão do pacote 1.0.0 · commit 91bb222 · 14/11/2026
Empresa e dados fictícios (SMA)

Repositório: `https://github.com/danrley-ribeiro/fin-dept-multiagents-project`
Documentação navegável: `https://fin-dept-multiagents-project.readthedocs.io`

Sumário

Resumo **2**

1 Problema e escopo **2**

2 Requisitos e rastreabilidade **2**

3 Arquitetura **2**

3.1 Agentes, papéis e serviços . . . 2

3.2 O que é BDI, o que é reativo e por quê (ADR-010) . . . 3

4 Comunicação e protocolos **4**

5 Coordenação e comportamento coletivo **5**

6 Segurança, identidade e acesso **5**

7 Cognição assistida e LLM opcional: proposta não é crença **6**

8 Implantação, portes e segmentos **6**

9 Testes e reprodutibilidade **6**

10 Experimentação **7**

10.1 Por que refazer o experimento . . . 7

10.2 Perguntas, braços, condições e métricas . . . 7

10.3 Resultados . . . 8

10.4 Três rodadas . . . 11

10.5 Comportamento coletivo observado . . . 12

10.6 O que não se confirmou . . . 13

10.7 Desvios do pré-registro . . . 13

10.8 Ameaças à validade . . . 13

11 Limitações **14**

12 Conclusão **14**

A Grafos de rastreabilidade por parte **15**

Referências **18**

Resumo

Este relatório descreve a versão final de um sistema multiagente (SMA) que executa rotinas de controladoria de uma empresa fictícia: um Orquestrador e cinco agentes especialistas (Custos, Orçamento, Resultados, Controles Internos e Relatórios) que se comunicam por um barramento com protocolos em máquina de estados, sob uma política de aprovação humana e com toda decisão registrada num trace encadeado. O experimento final, pré-registrado antes de existir código para rodá-lo, compara o SMA com um workflow centralizado *funcionalmente equivalente* em 9.360 execuções com 30 seeds e falhas sorteadas. O resultado central é desfavorável ao paradigma e é relatado como tal: **com as mesmas funções, o SMA empata em qualidade** (0 pares diferentes em 240) **e perde em custo e em robustez** quando mensagens se perdem (64,2% de execuções corretas com 15% de perda, contra 100% do workflow). A cognição local não mostrou ganho significativo na medida registrada. Nenhuma crítica foi publicada sem tratamento e nenhum dos 2.227 ataques foi aceito indevidamente, em nenhuma condição. O experimento rodou três vezes; as correções entre as rodadas (uma delas vinda de uma correção simulada independente) foram feitas depois de ver resultados, e nenhuma rodada posterior à primeira é teste confirmatório. O que a arquitetura de agentes entrega e o workflow não entrega — separação auditável de responsabilidades, veto independente, decisão humana atestada, negociação e extensibilidade — é descrito como propriedade do desenho, não como vitória numérica.

1. Problema e escopo

A controladoria de uma empresa fecha o resultado do mês e avalia o orçamento a partir de fontes que divergem (ERP e planilhas), sob regras que dependem do porte (alçadas, segregação de funções, materialidade) e com decisões que não podem ser automáticas: liberar um fechamento com não conformidade crítica é decisão de uma pessoa com cargo para isso. O projeto modela esse trabalho como um SMA porque ele tem as três características que justificam agentes (Wooldridge 2009; Cancian 2026): responsabilidades distintas que precisam ficar separadas (quem calcula não aprova, quem julga conformidade pode vetar), dependências entre especialistas que podem falhar e um ambiente que muda enquanto se age (correções aprovadas, prazos, pedidos concorrentes do mesmo período). A condição de rejeição estabelecida na DSM1 continua valendo: se um controlador centralizado com as mesmas regras fizer o mesmo trabalho com menos custo, o paradigma não se justifica pelo resultado. O capítulo de experimentação testa exatamente isso.

Escopo da versão final. Seis portes (MEI, micro, pequena, média, média II e grande) e quatro segmentos (software e serviços, comércio, serviços, indústria); duas intenções do catálogo (`fechar_mes` e `avaliar_orcamento`); dados de um ERP simulado, gerados por seed com gabarito, de planilhas Excel lidas por um servidor MCP ou de fontes genéricas por conectores (REST JSON, cliente MCP, planilha fora do modelo), sempre com mapeamento confirmado por uma pessoa; execução numa máquina só, para quem está nela (o servidor só aceita loopback). Exposição em rede, conectores de fornecedor e integração com ERP real ficam fora do escopo por decisão do dono do produto.

2. Requisitos e rastreabilidade

Os modelos AOSE (Tropos, Gaia e Prometheus; Bresciani et al. 2004; Wooldridge et al. 2000; Padgham e Winikoff 2004) ficam numa fonte única, `models/*.yaml`: problemas, objetivos, requisitos, papéis, agentes, protocolos, normas, serviços, componentes, testes e métricas, cada um com identificador estável. O `tools/trace.py --check` falha diante de identificador órfão, ligação quebrada, requisito sem cadeia completa, teste marcado como executado sem a função correspondente na suíte ou componente implementado sem o caminho no código. Na versão entregue: 510 objetos, 26 requisitos com cadeia completa, 289 testes modelados (289 executados), 29 métricas e 0 erros. Os 7 grafos do Apêndice A mostram a cadeia requisito → papéis → protocolos e normas → testes → métricas, um grafo por parte, com no máximo quatro requisitos cada.

A DSM4 acrescentou dois requisitos: REQ-F20 (Resultados, Custos e Relatórios com deliberação BDI nos níveis de cognição `local` e `llm`, com as classes reativas preservadas no nível `basico`) e REQ-F21 (conhecimento normativo com proveniência). As métricas MET-41 a MET-47 operacionalizam o experimento (robustez, recuperação, custo frente ao workflow equivalente, equivalência funcional, ganho da cognição, ataques e invariantes sob falha). Os dois últimos lotes da DSM4 acrescentaram REQ-F30 e REQ-S20 (conectores e entendimento de fontes, com as normas NORM-30 a NORM-32 e a métrica MET-50) e REQ-S06 (acesso avançado, que estende o REQ-S05, com NORM-14, NORM-15 e MET-19). As contagens acima e os grafos do apêndice são gerados dos modelos da versão compilada.

3. Arquitetura

3.1 Agentes, papéis e serviços

A Figura 1 resume a arquitetura final. O sistema roda em processo, com relógio lógico (ADR-003): cada agente é um objeto com estado próprio, e o barramento entrega as mensagens em ordem determinística, o que torna toda execução reproduzível por seed e permite injetar falhas. São 6 agentes, 11 papéis (incluindo solicitante, aprovador, operador, auditor e administrador, que são pessoas), 6 protocolos, 20 normas e 9 serviços de plataforma.

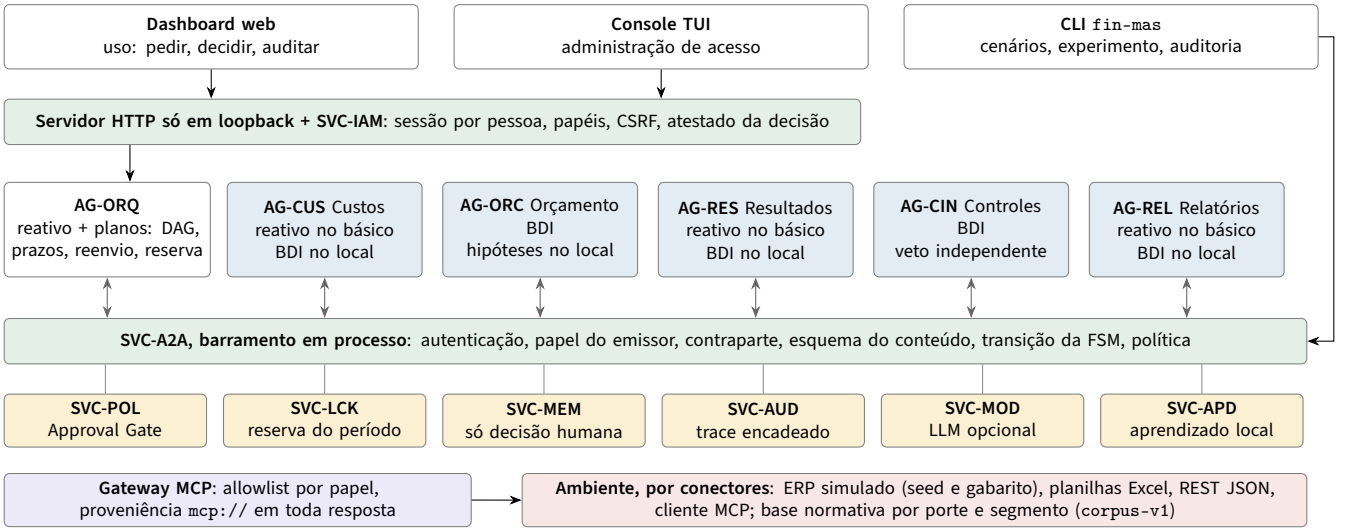


Figura 1: Arquitetura final. Especialistas e Orquestrador só falam pelo barramento; só acessam dados pelo gateway MCP; efeito externo (`erp.corrigir`) só com aprovação humana decidida no SVC-POL. Fonte editável: `diagramas/arquitetura_final.png` e `modelos-editaveis/arquitetura_final.mmd`.

Fontes de dados (ADR-011). Abaixo do gateway, uma interface `Conector` entrega os dados num modelo canônico, com proveniência por aba: ERP simulado, pasta de planilhas, planilha fora do modelo, REST JSON genérico e cliente MCP por stdio. Os agentes continuam vendo as mesmas tools pela mesma allowlist; falha da fonte vira `mcp_denied` com o motivo e falha explícita ao solicitante. O *entendimento* de uma fonte nova (contrato OpenAPI, amostra JSON, tools MCP ou planilha qualquer) é determinístico: infere tipos e sugere o mapeamento por nome, sinônimos e conteúdo, cada sugestão com confiança e motivo, e o mapeamento só vale depois de confirmado por uma pessoa (NORM-30). O LLM é opcional também aqui: só sugere para campos sem sugestão determinística, recebe nomes e tipos, sem valores, e passa pela mesma validação (NORM-31). Não há conector de fornecedor; o alvo de teste é um ERP de demonstração em loopback, num formato diferente do canônico.

Tabela 1: Agentes: o que cada um decide, onde é BDI e onde é reativo, e onde o LLM é permitido.

Agente	O que decide	Nível `basico`	Nível `local`	LLM
AG-ORQ	decomposição da intenção em DAG, prazos, reenvio (uma vez), reserva do período, ticket do Approval Gate; não decide conformidade nem desvio	reativo a protocolos + biblioteca de planos	igual	nunca (NORM-07)
AG-CUS	critério de rateio quando o direcionador do período não serve	reativo	BDI: precisão × simplicidade	nunca
AG-ORC	fonte confiável (ERP × planilha), o que é desvio, a quem perguntar, se vale buscar evidência	BDI, sem hipóteses	BDI + hipóteses locais, memória aprovada e aprendizado	opcional: hipóteses, narrativa
AG-RES	consolidar com ou sem insumo, com ressalva ou falhando; explicar variação	reativo	BDI: completude, tempestividade, explicabilidade	opcional: comentário
AG-CIN	aprovar, apontar, vetar com correção ou vetar; reconsiderar após correção ou waiver	BDI	BDI + base normativa	nunca
AG-REL	estrutura do relatório (exceção, sumário, completo)	reativo	BDI (pesa pouco; ver texto)	opcional: síntese rotulada

3.2 O que é BDI, o que é reativo e por quê (ADR-010)

O ciclo BDI é o mesmo para todos (Rao e Georgeff 1995; Bratman 1987): perceber, revisar crenças (sempre com a fonte), reconsiderar intenções, gerar opções, deliberar entre planos com contexto e utilidade e executar; plano que falha é marcado e o agente delibera de novo sem ele. A utilidade é a soma dos pesos dos desejos permanentes que o plano atende, e os pesos vêm do porte (`models/portes.yaml` e `models/cognicao.yaml`), de modo que a escolha muda com a empresa. No cenário `res_insumo_faltante`, por exemplo, o AG-RES não recebe o orçamento, tenta de novo, dá o insumo por indisponível e, na média empresa, consolida com ressalva; com `--porte grande`, onde a completude pesa mais, falha de forma explícita, e o Orquestrador reenvia a subtarefa.

A pedido do dono do produto, todos os especialistas viraram BDI na DSM4, mas como *variantes*: as classes reativas continuam no nível `basico`, que é o braço de comparação do experimento e o nível dos cenários revisados da DSM3 (cujos traces não mudaram). A apostila adverte contra a agentificação excessiva, isto é, dar cognição a quem só aplica uma fórmula (Cancian 2026). Adotamos o critério de que um agente merece crenças, desejos e intenções quando escolhe entre alternativas sob incerteza, quando o mundo muda enquanto ele age ou quando depende de outros que podem falhar. Por esse critério, **a**

cognição se justifica no AG-RES (dependência, prazo, incerteza), **pouco no AG-CUS** (a escolha do rateio existe, mas é uma cadeia curta e síncrona; o ganho é transparência: o reativo aplica 60/40 sem perceber que a tabela do período estava errada) e **não se justificou no AG-REL**: a escolha entre três estruturas é guardada por contexto e nenhum plano falha; uma tabela de decisão faria o mesmo. O ADR-010 registra isso, e o experimento confirma que o pacote cognitivo não mudou o resultado de forma distinguível do acaso (Seção 10.3). A estratégia de compromisso (Rao e Georgeff 1991; Kinny e Georgeff 1991) virou parâmetro (`cego`, `obstinado`, `aberto`); nos cenários `compromisso_*`, só o aberto chega ao gabarito, porque é o único que larga a intenção de sinalizar quando o AG-CIN contesta o lançamento.

4. Comunicação e protocolos

Toda mensagem é ⟨remetente, destinatário, performativo, conteúdo, ontologia, conversation_id⟩ com prazo `reply_by`, no estilo da FIPA-ACL (FIPA 2002a; FIPA 2002b). Cada protocolo declara em `models/protocols.yaml` a FSM, os papéis participantes, quem pode emitir cada performativo, os eventos locais e o esquema do conteúdo de cada performativo. O barramento confere, nesta ordem, remetente registrado e credencial, envelope, destinatário, papel do emissor e do destinatário, esquema, abertura, contraparte e transição da conversa, e os validadores da política; uma recusa grava `rejected` com a etapa e o motivo e nunca altera conversa nem agenda entrega. Resposta depois do prazo é descartada, não rejeitada: é atraso, não ataque.

Tabela 2: Protocolos, finalidade e transições inválidas que viram teste.

Protocolo	Finalidade	Exemplos de transição ou emissão recusada (testada)
PROT-SOL	pedido da liderança e resposta final ou falha explícita	intenção fora do catálogo termina em `not-understood`
PROT-DEL	delegar subtarefa com prazo; o especialista pode negociar o prazo	`inform` antes de `agree`; `propose` antes de `agree`; segunda `propose` sem resposta; `accept-proposal` por quem não é o Orquestrador
PROT-QRY	especialista consulta outro sem acessar suas regras	`inform` com conversation_id desconhecido
PROT-CMP	parecer de conformidade com veto	`publicar` em VETADO; `publicar` pelo AG-CIN; `waiver_humano` sem aprovação
PROT-APR	reter ação restrita até decisão de pessoa autenticada	`execute` em PENDENTE; `approve` em NEGADA, APROVADA, EXECUTADA ou EXPIRADA
PROT-LCK	exclusão mútua do período	segunda reserva sobreposta recebe `reserve-failure`

Negociação. No PROT-DEL, o especialista que não cabe no prazo pode propor uma extensão (`propose`); o Orquestrador aceita ou recusa por regras de quem coordena: só prazo é negociável, nenhuma extensão com período reservado, uma por subtarefa e no máximo 20 ticks. Aceita, o barramento passa a valer o prazo novo e o temporizador antigo deixa de ter efeito. Na DSM4 a negociação está no AG-ORC; a ablação mostrou que ela não muda a medida designada (Seção 10.3).

Correção do protocolo feita pelo experimento. O barramento muda o estado da conversa no *envio*. Na v0.5.0, se a resposta final de um especialista (ou o parecer do AG-CIN, ou a mensagem de correção) se perdia na entrega, a conversa já constava como concluída, o temporizador não avisava ninguém e a solicitação ficava sem resposta. Os cenários fixos nunca perdiam respostas, só pedidos; o modelo de falhas aleatórias perdeu, e a primeira rodada do experimento registrou 807 execuções com o invariante INV-07 violado. A correção: toda mensagem perdida depois da abertura da conversa agenda um aviso de prazo ao iniciador, que reenvia uma vez ou falha de forma explícita (diagrama em `diagramas/correcao_mensagem_perdida.png`). A correção simulada da DSM4 achou dois defeitos restantes no mesmo transporte: uma mensagem anterior entregue com 3 ticks ou mais de atraso apagava a marca da perda (C1), e um aviso de decisão humana perdido no caminho para o AG-CIN contornava a POL-06 ou gerava um segundo ticket (C2). Agora a perda é marcada pela posição da mensagem na conversa e esses avisos têm reentrega pelo transporte, até cinco tentativas (TEST-420 e TEST-421). Na segunda e na terceira rodada do experimento, 0 violações.

5. Coordenação e comportamento coletivo

Tabela 3: Mecanismos de coordenação, quem decide e onde se vê.

Mecanismo	Quem decide	Protocolo	Cenário
DAG, prazos e reenvio	AG-ORQ	SOL, DEL	`fechar_mes`, `falha_especialista`
Consulta direta entre especialistas	quem consulta (AG-ORC, AG-RES)	QRY	`desvio_irregular`, `orc_sem_cin`
Veto, correção e reavaliação	AG-CIN	CMP	`veto_correcao`, `correcao_parcial`
Decisão humana vinculada ao veto	pessoa autorizada + SVC-POL	APR	`veto_waiver`, `decisao_por_pessoa`
Exclusão mútua do período	SVC-LCK	LCK	`expediente_sma`
Memória entre ciclos	AG-CIN + SVC-MEM + SVC-POL	APR, CMP	`reincidencia_waiver`
Ação epistêmica dirigida por hipótese	AG-ORC	QRY	`orc_hipotese_local`
Negociação de prazo	AG-ORC propõe, AG-ORQ decide	DEL	`negociacao_prazo`, `negociacao_recusada`

O comportamento coletivo é observável no trace. Em `reincidencia_waiver`, a decisão humana de agosto vira memória do AG-CIN; em setembro, a memória muda a crença dele, a crença muda o veto, o veto muda as opções que a política abre e a nova decisão do humano é executada pelo Orquestrador e reavaliada pelo AG-CIN. Nenhum agente sozinho tem a regra "waiver não se repete": ela emerge de três componentes com responsabilidades distintas. Sem falhas, no fechamento, 77% das decisões registradas são tomadas fora do Orquestrador no SMA básico (17,2 decisões por fechamento) e 84% com os especialistas BDI (24,7); o controlador único do workflow toma todas (6,1). O Contract Net (Smith 1980) foi avaliado e não adotado: há um especialista por capacidade, e um leilão com um único proponente só acrescentaria mensagens e um ponto de falha.

6. Segurança, identidade e acesso

O modelo de ameaças (`docs/dsm3/seguranca.md`) parte de quem pode atacar de dentro do processo e da interface: remetente sem credencial, agente legítimo fora do seu papel, resposta para quem não participa da conversa, decisão forjada, reutilizada ou atrasada, processo que controla a caixa do aprovador sem ser a pessoa certa, chamada à API sem sessão, CSRF e DNS rebinding, força bruta, escalada de privilégio, adulteração de cadastro, trilha, memória ou trace, e texto de modelo que tenta decidir. Os controles: credencial por identidade (o barramento guarda só o hash), registro fechado depois da montagem, papel por performativo, esquema, ticket do Approval Gate com hash do veto, uso único e prazo pela entrega prevista (POL-08), atestado HMAC da sessão da pessoa (POL-09), cargo e segregação de funções contra a pessoa real (POL-02, POL-03), quem pede não aprova (POL-13), sessões com prazo e revogação (IAM-01 a IAM-07), arquivos selados com contador e chave fora da pasta de dados, falha fechada e redaction de segredos e dados pessoais antes de gravar.

Dois cenários adversariais disparam os ataques enquanto o veto aguarda o aprovador: `ataque_decisao_forjada` (14 de 14 rejeitados, entre eles os quatro relatados pelo professor na DSM2) e `ataque_acesso` (15 de 15). O verificador de invariantes lê só o trace e confere 10 propriedades em qualquer execução: nenhuma publicação de pacote vetado sem tratamento, nenhum efeito externo sem aprovação decidida, toda transição existe na FSM, toda decisão aceita tem pessoa e sessão quando o acesso está ligado, nenhuma crença tem proponente como fonte, hipótese só muda de estado com evidência, toda solicitação recebe resposta explícita e nenhum segredo aparece no trace; o lote de acesso avançado acrescenta invariantes próprios, como o aval da dupla aprovação (INV-09). A Seção 10.3 mostra que essas garantias se mantiveram com o sistema degradado.

Fora do modelo, e declarado: código com acesso ao objeto Python de outro agente (a raiz de confiança é o processo), quem lê a pasta de chaves e a máquina comprometida.

Acesso avançado (ADR-012). A última etapa fechou o que a DSM3 deixou aberto de propósito. Segundo fator TOTP (RFC 6238) só com a biblioteca padrão, com anti-replay pelo passo e códigos de recuperação de uso único, obrigatório por política para administrador e aprovador; a senha certa abre só uma pré-sessão que nenhuma rota aceita. Alçada por pessoa (POL-10): o AG-CIN informa no veto a exposição dos lançamentos críticos, e a liberação só vale se couber na alçada do cargo de quem decide. Delegação com prazo, teto e escopo, sem subdelegação (POL-11). Dupla aprovação acima do limite do porte, com aval (`endorse`) de uma pessoa e aprovação de outra (POL-12). Escalonamento do ticket a um nível acima quando o prazo corre sem decisão (POL-14). Cofre de segredos sobre o arquivo selado, que garante integridade e controle de acesso mas *não* cifra os valores: a biblioteca padrão não tem cifra autenticada e o projeto não inventa criptografia. Memória (SVC-MEM) gravada na trava entre processos e cópia de outra pasta adotável à mão, e várias empresas por cadastro, com empresa ativa por sessão. Os campos novos só aparecem com o SVC-IAM ligado, e os traces revisados do nível básico não mudaram. O cenário `ataque_acesso_avancado` tenta 12 ataques (TOTP repetido, recuperação reutilizada, pré-sessão em rota comum,

delegação forjada, expirada ou subdelegada, a mesma pessoa nos dois passos, decisão acima da alçada e de outra empresa), e 12 são recusados. Ficam limitados: o escalonamento sobe um nível, uma vez; a trilha é uma por cadastro; delegações, seletor de empresa, segundo fator e cofre não têm tela no dashboard web (só API, CLI e TUI).

7. Cognição assistida e LLM opcional: proposta não é crença

O AG-ORC (e, no nível `local`, o AG-RES) recebe *propostas* de hipótese sobre a causa de um desvio, vindas de regras locais offline ou, se a flag estiver ligada, de um LLM. Proposta não é crença (ADR-008). Ela passa por cinco regras determinísticas: tipo da lista fechada e alvo da tarefa; toda evidência citada é crença que o agente tem; nenhum dígito no texto (valores só por marcadores que o agente resolve com as próprias crenças); nenhuma ação proposta; nenhum marcador sem evidência citada. Aceita, vira hipótese num repositório separado e gera um desejo epistêmico: buscar a evidência (consulta ao AG-CIN, cálculo sobre o histórico, negociação de prazo) ou arquivar. Quem muda a avaliação é a crença revisada pela evidência de fonte determinística, pelos planos de sempre. Isso segue a orientação da apostila de tratar a saída de modelo como proposta validada por esquema e política, com barreira determinística, "e não outro modelo" (paráfrase de Cancian 2026).

O LLM é opcional, desligado por padrão e proibido no Orquestrador, no AG-CUS e no AG-CIN (NORM-07). Onde é permitido, o texto passa por conferência numérica por rótulo (um número verdadeiro sob o rótulo errado também derruba o texto), vai ao fim do relatório rotulado como redação não verificada e, sem consentimento, nada sai para provedor externo. Os testes usam só mocks e um servidor falso em loopback; nenhum provedor real foi exercitado e a qualidade de um modelo real não foi medida. O LLM fica fora do experimento, para não confundir o efeito do paradigma com o do modelo. Aprendizado: cada regra local acumula confirmações e refutações de evidência verificada em competências anteriores, e a confiança resultante só entra no contexto de planos que custam mensagem; o registro fica num arquivo selado próprio, fora da memória, que só aceita decisão humana (NORM-08). A base normativa (`corpus-v1`) é buscada por BM25 offline (Robertson e Zaragoza 2009) e, sem cobertura suficiente, devolve vazio: o achado de duplicidade sai marcado "sem evidência", em vez de receber uma citação inventada.

8. Implantação, portes e segmentos

Três formas de implantar com o mesmo programa e a mesma pasta de dados: do checkout (`tools/iniciar.py` prepara ambiente, dashboard e abre o escritório), pelo pacote instalável (`make wheel`, com os YAML e o dashboard embutidos; testado num venv limpo fora do repositório) e por contêiner (imagem em três estágios, usuário sem privilégio, porta publicada só em `127.0.0.1`, volumes de dados e de chaves separados). A imagem foi construída e executada com as opções do `compose.yaml`; o `docker compose` em si não foi executado nesta máquina, e o arquivo é conferido por teste de leitura. Backup e restauração conferem o selo do manifesto e o hash de cada arquivo antes de gravar e recusam rollback sobre uma instalação que já existiu. MEI e Média empresa II foram acrescentados com as fontes legais (Brasil 2006; BNDES 2026) sem mudar nenhum valor dos portes anteriores; os segmentos mudam o direcionador do rateio e a estrutura de custos, e o gabarito é calculado com o mesmo direcionador. Com os conectores, o servidor continua só em loopback, mas um conector pode precisar sair para a rede: host externo só com liberação explícita do administrador (PERM-DAD-REDE, NORM-32), registrada na trilha; a credencial da fonte vai para o cofre, nunca volta pela API, pelo trace ou pela trilha e só é enviada ao host e porta a que foi vinculada.

9. Testes e reprodutibilidade

Tabela 4: Suíte de testes na versão entregue (contagem pela coleta; execução na geração deste relatório).

Conjunto	Testes	O que cobre
`tests/unit`	95	os mesmos da DSM3 (nenhum unitário novo, por decisão dos autores)
`tests/e2e`	426	cenários completos verificados pelo trace: protocolos válidos e inválidos, ataques, equivalência do workflow, especialistas BDI, portes
`tests/integration`	123	servidor HTTP real, CLI em subprocesso, wheel, contêiner, backup, experimento
`tests/tui`	23	console de administração pelo Pilot do Textual
pytest, total	**667**	resultado nesta geração: 667 passaram, 0 falharam
vitest (dashboard)	3	reducer e regra da justificativa do waiver
Playwright (dashboard)	40	roteiros de uso real no navegador; não executados nesta geração
`cenarios --verificar`	64 de 64	cada cenário duas vezes: resposta explícita, invariantes e mesmo hash

Os testes novos das DSM3 e DSM4 são todos de ponta a ponta, de integração ou de interface; os achados corrigidos da correção simulada da DSM4 entraram com teste próprio (TEST-420 a TEST-449). A reprodutibilidade tem três camadas: o mesmo cenário com a mesma seed dá o mesmo hash de trace (conferido em todos os cenários); o hash dos 140 traces revisados da DSM3 continua o mesmo no nível `basico`; e o `execucoes.csv` do experimento sai idêntico byte a byte numa segunda execução completa, em outro processo (SHA-256 `9d5126a6...` no manifesto). O experimento revelou um defeito

de reprodutibilidade antes da primeira rodada (o trace dependia da ordem de iteração de um conjunto, que muda entre processos), invisível para `cenarios --verificar` porque ele compara duas execuções no mesmo processo.

10. Experimentação

10.1 Por que refazer o experimento

O experimento da DSM3 recebeu duas críticas procedentes: o workflow de comparação não tinha veto, correção nem aprovação (parte da vantagem vinha das funções, não do paradigma), e as dez seeds só confirmavam o determinismo (variância zero, porque as métricas dependiam de plantios fixos). O redesenho responde às duas com um workflow centralizado *funcionalmente equivalente*, com a equivalência garantida por teste, e com aleatoriedade controlada: plantios, falhas, perfil do aprovador e ataques sorteados por seed, por fluxos independentes (`random.Random(f"{seed}:{fator}")`). Perguntas, hipóteses, métricas, plano de análise, critérios de parada e ameaças previstas foram escritos e versionados antes do código do experimento (Nosek et al. 2018); o histórico do git é a prova (`docs/dsm4/experimento.md`).

10.2 Perguntas, braços, condições e métricas

Tabela 5: Perguntas de pesquisa, hipóteses pré-registradas e veredito na versão final (terceira rodada).

	Pergunta	Hipótese (resumo)	Veredito
RQ1	Com as mesmas funções, o SMA entrega mais qualidade?	H1a: SMA básico e workflow equivalente idênticos sem falhas; H1b: o workflow mínimo é pior por função	H1a e H1b confirmadas
RQ2	Quão robusto é cada braço sob falha?	H2a: SMA menos robusto que o workflow sob perda, indisponibilidade e combinadas; H2b: robustez cai com a perda; H2c: empate com humano lento; H2d: nenhuma crítica sem tratamento	H2a confirmada para 15%, 30% e combinadas, não significativa para 5% e indisponibilidade; H2b, H2c, H2d confirmadas
RQ3	Quanto custa coordenar e o controle de acesso?	H3a: SMA mais caro em mensagens e ticks; H3b: acesso não acrescenta mensagens nem ticks, só auditoria	H3a confirmada em mensagens; em latência, só sob a premissa do workflow; H3b em parte (o trace quase não cresceu)
RQ4	O SMA se recupera, e em quanto tempo?	H4a: maioria das atingidas recupera; H4b: mediana $\geq$ 10 ticks; H4c: parte sem resposta (defeito previsto)	H4a só para falhas leves e 15%; H4b confirmada; H4c confirmada na 1.ª rodada e eliminada a partir da 2.ª
RQ5	Depende do porte e dos parâmetros?	H5a: micro classifica pior; H5b: efeitos de tentativas, prazos, limiar, TTL e correções	H5a confirmada; H5b em parte
RQ6	Os ataques passam quando há falha?	H6a: zero aceitos; H6b: resultado atacado igual ao não atacado	H6a: nenhum aceito indevidamente; H6b confirmada no bloco A, não testada no D
RQ7	A cognição local melhora o resultado?	H7a: igual sem falhas; H7b: melhor sob perda, sobretudo no subgrupo com pista; H7c: custa mais mensagens	H7a confirmada; H7b e H7c não confirmadas

Braços. `sma_basico` (o SMA da DSM3); `sma_local` (o mesmo com cognição local: hipóteses do AG-ORC e, a partir da segunda rodada, especialistas BDI); `wf_equivalente` (um controlador único e sequencial com as mesmas regras de reconciliação, atribuição de desvio, conformidade com veto, correção e aprovação, o mesmo SVC-POL e o mesmo aprovador simulado, sem agentes, negociação nem replanejamento); `wf_minimo` (o baseline da DSM3, intacto, só sem falhas). Nenhum braço usa LLM. **Carga por seed**, igual para todos os braços: 4 portes $\times$ 2 intenções, 7 tipos de plantio com probabilidade 0,35 cada e um perfil de aprovador. **Condições**: sem falhas; perda independente por mensagem entre agentes de 5%, 15% e 30%; um especialista fora do ar por 8 a 30 ticks; aprovador lento ou ausente; falhas combinadas, com e sem os ataques. A perda é sorteada por mensagem com chave própria, para que a mesma mensagem tenha o mesmo destino em braços diferentes da mesma seed (números aleatórios comuns). O Orquestrador não cai (ponto único de falha conhecido, não exercitado).

Tabela 6: Blocos do experimento (9.360 execuções, 30 seeds, nenhuma com erro).

Bloco	Desenho	Execuções	Para quê
A, principal	3 braços $\times$ 8 condições + workflow mínimo sem falhas; 4 portes $\times$ 2 intenções $\times$ 30 seeds	6.000	RQ1 a RQ4, RQ6, RQ7, porte
B, varredura	porte médio, SMA básico, sem falhas e combinadas; um parâmetro por vez	2.160	RQ5 (parâmetros)
C, ablação	porte médio, SMA local completo, um mecanismo desligado por vez; desvio irregular sempre plantado; pedido concorrente do mesmo mês	1.080	contribuição de cada mecanismo
D, acesso	porte médio, SMA básico com SVC-IAM ligado, sem falhas e combinadas com ataques ao acesso	120	RQ3 (acesso), RQ6

Métricas (todas do trace e do gabarito plantado, nunca das regras dos agentes). A principal é a *execução correta*: resposta explícita, nenhuma crítica publicada sem tratamento e resultado igual ao da mesma execução sem falha (status, DRE, contas sinalizadas, contas atribuídas a controle e correções). *Degradação segura* é responder sem publicar crítica, mas com resultado diferente (falha explícita, bloqueio, ressalva a mais). Completam: classificação correta, conformidade e DRE corretas, mensagens de coordenação (sem as três do pedido do solicitante), latência em ticks, recuperação (da primeira falha à resposta), ataques aceitos e violações de invariantes. O tempo de parede fica num arquivo à parte, marcado como não reproduzível, e nunca entra em teste.

Análise. A unidade estatística é a seed ($n = 30$): o valor de uma seed é a média da métrica nas células daquela seed, porque células da mesma seed compartilham plantios e perdas. Intervalos de 95% por bootstrap percentil com 2.000 reamostragens (Efron e Tibshirani 1993); comparações pareadas por Wilcoxon de postos sinalizados (Wilcoxon 1945), exato até 25 pares; grupos independentes por Mann-Whitney (Mann e Whitney 1947); tamanho de efeito pelo delta de Cliff (Cliff 1993), com os limiares de Romano et al. (2006); correção de Holm dentro de cada família (Holm 1979), $\alpha = 0,05$ (60 testes em 9 famílias). Identidade não se prova com p alto: H1a é julgada pelo número de pares diferentes, que tem de ser zero. Só biblioteca padrão, conferida contra exemplos calculados à mão. Comparações idênticas em todos os pares não são testadas nem entram na contagem do Holm (regra aplicada depois da primeira execução); com elas na família, nenhuma das 9 famílias muda de leitura (o p ajustado de 5% de perda passaria de 0,125 a 0,1875; o do limiar de 20%, de 0,0938 a 0,125). Na RQ4, as comparações não pareadas usavam a execução como unidade, o que é pseudo-replicação; na versão final o valor de cada seed é a média nas execuções atingidas (desvio declarado). **Poder**: com k seeds diferentes, o menor p bilateral do Wilcoxon exato é $2/2^k$ (0,0625 com 5, 0,125 com 4); os "não significativos" com 5 seeds diferentes ou menos são falta de poder, não evidência de ausência de efeito.

10.3 Resultados

RQ1 — qualidade com funções iguais. Sem falhas, SMA básico e workflow equivalente deram o mesmo resultado nos 240 pares (0 diferentes; Tabela 7). A equivalência também é conferida por teste nos cenários comparáveis da DSM3 e em cargas fora das seeds do experimento. O workflow mínimo da DSM3 classifica +38,3 pp pior em relação ao SMA [23,3; 53,3] (p ajustado $<$ 0,001) e publica críticas sem tratamento; a conformidade ele acerta: enxerga os mesmos achados e não tem o que fazer com eles. **A crítica do professor estava certa**: a vantagem de qualidade medida na DSM3 era das funções (veto, correção, reconciliação), não do paradigma. O empate é em boa parte construído: o workflow foi escrito depois do SMA, lendo os agentes, e testado até igualar.

Tabela 7: RQ1, sem falhas, bloco A: média por seed (IC de 95%).

Braço	Classificação correta	Conformidade	DRE	Críticas sem tratamento	Publicação
SMA básico	75,0% [63,3%; 85,8%]	100%	100%	0,00	100%
SMA com cognição local	75,0% [63,3%; 85,8%]	100%	100%	0,00	100%
workflow equivalente	75,0% [63,3%; 85,8%]	100%	100%	0,00	100%
workflow mínimo (DSM3)	36,7% [20,0%; 53,3%]	100%	100%	0,68	100%

A classificação não chega a 100% em nenhum braço por três situações em que o gabarito pede o que uma resposta de rótulo único não dá (Seção 10.8); elas atingem os braços por igual.

RQ2 — robustez. O SMA é menos robusto que o workflow sob perda de mensagens, e por muito a partir de 15% (Tabela 8, Figura 2). Com 5% de perda e com um especialista fora do ar, a diferença tem o sinal previsto e não é significativa (5 e 2 seeds diferentes: o desenho não tem poder para decidir). A robustez cai com a perda (p ajustado $<$ 0,001 e $<$ 0,001), mas a ordem é em parte artefato: com números aleatórios comuns, a n-ésima ocorrência de uma mensagem usa o mesmo sorteio nos três níveis, e o que se perde com 5% também se perde com 15% e 30%. Com humano lento os braços empatam exatamente: o ticket expira nos dois e a publicação fica bloqueada. Nenhum braço com veto publicou crítica sem tratamento, em nenhuma condição: quando falha, o SMA falha fechado. O workflow ganha por construção, porque o modelo de falhas só atinge mensagens entre componentes e ele não as tem; o experimento mede o tamanho da conta.

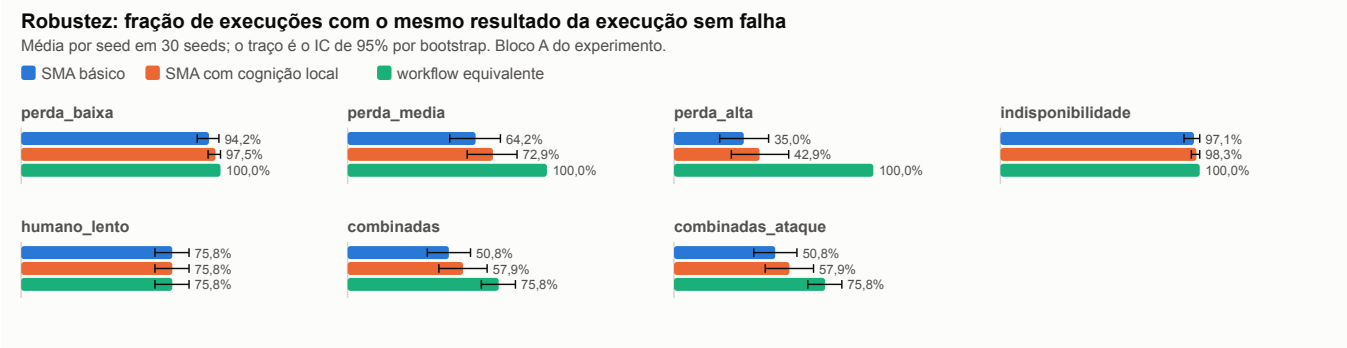


Figura 2: Robustez por condição, média por seed com IC de 95% (gerada pelo comando do experimento a partir de `execucoes.csv`).

Tabela 8: RQ2, execução correta por condição (bloco A). Diferença: SMA básico menos workflow equivalente, em pontos percentuais, com IC de 95%; teste de Wilcoxon pareado por seed, p ajustado por Holm.

Condição	SMA básico	SMA local	Workflow	Diferença	Seeds dif.	p ajust.
perda de 5%	94,2% [88,3%; 99,2%]	97,5%	100%	−5,8 pp [−11,7; −0,8]	5	0,125
perda de 15%	64,2% [51,2%; 76,7%]	72,9%	100%	−35,8 pp [−48,8; −23,3]	19	< 0,001
perda de 30%	35,0% [22,9%; 47,5%]	42,9%	100%	−65,0 pp [−77,1; −52,5]	28	< 0,001
indisponibilidade	97,1% [92,1%; 100%]	98,3%	100%	−2,9 pp [−7,9; 0,0]	2	0,500
humano lento	75,8% [67,1%; 84,2%]	75,8%	75,8%	idêntico em todos os pares	0	—
combinadas	50,8% [40,0%; 61,7%]	57,9%	75,8%	−25,0 pp [−37,1; −14,2]	14	< 0,001
combinadas + ataque	50,8% [40,0%; 61,7%]	57,9%	75,8%	−25,0 pp [−37,1; −14,2]	14	< 0,001

RQ3 — custo de coordenação e do controle de acesso. Sem falhas, o SMA troca 14,87 mensagens de coordenação a mais por solicitação [14,20; 15,53] e leva 3,2 ticks a mais [2,9; 3,5]; sob falhas combinadas, 31,1 ticks a mais [25,0; 37,5]; todas com p ajustado < 0,001 (Tabela 9, Figura 3). **A latência entre os braços é modelada, não medida**: no workflow cada etapa vale 3 ticks por premissa (`TICKS_POR_ETAPA`, a mesma do baseline da DSM3). Refeito só o workflow com outras premissas (exploratório), a latência sem falhas seria 8,8 ticks com 2 por etapa e 16,7 com 4: **com 4 o sinal se inverte**. Sob falhas combinadas o SMA segue mais lento até 5 por etapa (25,0 ticks no workflow). A conclusão firme da RQ3 é a de mensagens.

O controle de acesso por pessoa (bloco D, SVC-IAM ligado, contra as mesmas seeds do bloco A no porte médio) não mudou a latência em nenhuma seed (15,9 ticks dos dois lados, sem falhas); mensagens (18,70 contra 18,67) e registros do trace (141,0 contra 140,9) diferem em 2 seeds, nas quais a dupla aprovação acrescenta o aval da segunda pessoa; nenhuma mensagem rejeitada. Com falhas e ataques, 5,68 contra 2,75 mensagens rejeitadas, mas também 7,25 contra 3,50 ataques por solicitação (só o bloco D recebe os ataques ao acesso). A execução correta não serve para essa comparação: ela compara cada execução com a mesma execução sem falhas do mesmo bloco, e sem falhas é 100% dos dois lados por definição. A previsão de mais registros de auditoria não se confirmou: o que o acesso registra a mais vai para a trilha de acesso, outro arquivo, que não foi medido.

Tabela 9: RQ3, custo por solicitação (bloco A, média por seed).

	Mensagens de coordenação			Latência (ticks)		
Condição	SMA básico	SMA local	Workflow	SMA básico	SMA local	Workflow
sem falhas	15,75	15,75	0,88	15,9	15,9	12,7
perda de 15%	15,49	16,02	0,88	43,0	47,4	12,7
combinadas	13,60	13,97	0,64	49,2	52,5	18,1

RQ4 — recuperação. Depois da correção, o SMA responde sempre: 0 execuções sem resposta explícita. É propriedade testada nos parâmetros do experimento (atraso de até 2 ticks) e dos testes de caos (até 6, TEST-420), não demonstrada: a segunda rodada também respondia sempre, e o defeito C1 só aparecia com 3 ticks ou mais. Responder não é acertar: a maior parte das execuções atingidas por 30% de perda termina em falha explícita (Tabela 10), porque o Orquestrador reenvia uma vez e, se perde de novo, responde `failure`. A recuperação custa de 27 a 59 ticks na mediana, bem acima de um prazo de consulta. Com a seed como unidade, recuperar de perda leva mais que de indisponibilidade (50,6 contra 33,0 ticks, 30 x 13 seeds; p ajustado 0,0016, delta 0,65), e o braço local não se distingue do básico (53,7 contra 49,1; p 0,2642). Com a execução como unidade, na segunda rodada, essa última diferença dava p = 0,0314: era pseudo-replicação.

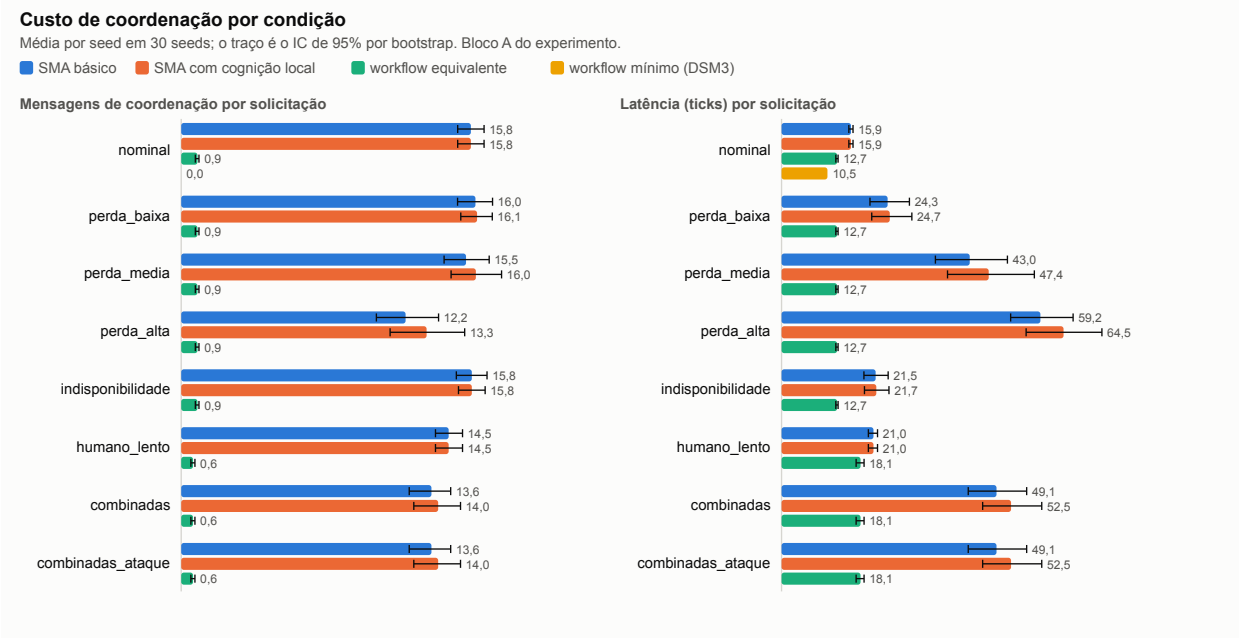


Figura 3: Custo de coordenação e latência por condição (o workflow mínimo só roda sem falhas).

Tabela 10: RQ4, SMA básico, execuções atingidas por pelo menos uma perda ou prazo esgotado (bloco A).

Condição	Atingidas	Mesmo resultado da nominal	Degradação segura	Sem resposta	Recuperação (mediana, ticks)
perda de 5%	105 de 240	91 (87%)	14	0	27
perda de 15%	189 de 240	103 (54%)	86	0	46
perda de 30%	220 de 240	64 (29%)	156	0	59
indisponibilidade	57 de 240	50 (88%)	7	0	33
combinadas	176 de 240	58 (33%)	118	0	54

RQ5 — porte e parâmetros. A microempresa classifica pior: 40,0% contra 86,7% na pequena (−46,7 pp [−63,3; −30,0], p ajustado $< 0{,}001$), em parte porque sem ERP não há segunda fonte para reconciliar quando a planilha diverge, em parte por dois efeitos da geração de dados nesse porte (Seção 10.8); o workflow tem os mesmos números em todos os portes. Na varredura (Tabela 11), mais tentativas aumentam a robustez e a latência (p ajustado $< 0{,}001$), prazo de subtarefa maior aumenta a latência ($< 0{,}001$) e sem correção não há crítica corrigida ($< 0{,}001$). Prazo de aprovação e TTL da reserva apontam no sentido previsto sem significância (4 seeds diferentes cada); o limiar de 5% não mudou nada e o de 20% derruba a classificação, mas perde a significância depois de Holm (p ajustado 0,0938).

Tabela 11: RQ5, varredura de parâmetros (bloco B, porte médio, SMA básico), na medida designada no pré-registro. Em negrito, o valor padrão.

Parâmetro	Condição	Medida	Nível: valor
máximo de tentativas	combinadas	execução correta	1: 36,7%; **2**: 51,7%; 3: 63,3%
prazo de subtarefa	combinadas	latência (ticks)	15: 36,6; **30**: 48,7; 60: 70,1
prazo de aprovação	combinadas	publicação (fechamento)	10: 20,0%; **20**: 26,7%; 40: 33,3%
TTL da reserva	combinadas	publicação (fechamento)	40: 13,3%; 80: 20,0%; **200**: 26,7%
limiar de desvio (%)	sem falhas	classificação correta	5: 86,7%; **10**: 86,7%; 20: 66,7%
máximo de correções	sem falhas	críticas corrigidas (fechamento)	0: 0,00; **2**: 1,33

RQ6 — ataques sob falha. No bloco A, 1.792 ataques ao Approval Gate em 128 execuções atacadas, com perda, atraso, indisponibilidade e humano lento ao mesmo tempo: 0 aceitos, e a execução atacada terminou igual à mesma execução sem ataque em todos os 240 pares do SMA básico e nos 240 do SMA local (H6b confirmada *no bloco A*). No bloco D, com o controle de acesso ligado, 435 ataques: 4 registrados como aceitos (fechamento, seeds 3, 7, 15 e 28), todos o mesmo ataque e nenhum indevido (0): o ataque supõe que a analista participou do lançamento vetado; nesses casos ela não participou, e a decisão é a de uma aprovadora autorizada, que a política aceita corretamente. **Esses casos não são neutros para o desfecho, e H6b não foi testada no bloco D**: o desenho não tem o par com o SVC-IAM ligado, com e sem os ataques ao acesso. O avaliador da correção simulada rodou esse par na versão anterior e viu 2 de 60 pares com desfecho diferente (seeds 7 e 28: o fechamento passava de bloqueado a publicado por uma decisão “ana corrige” emitida pelo roteiro de ataque, legítima pela política). Nos dados finais, o único par disponível (bloco D com ataques × bloco A com `combinadas_ataque`, que também desliga o

SVC-IAM) difere em 2 de 60, nas seeds 7 e 28, e mistura as duas coisas. O workflow equivalente não foi atacado: a bateria é contra o barramento de agentes, e o controlador único não tem as fronteiras que ela testa.

RQ7 — cognição local. Sem falhas, o braço local é idêntico ao básico (0 pares diferentes em 240), sem mensagem nem tick a mais; o custo aparece em decisões registradas (18,0 contra 13,4 por solicitação) e em trace. Sob perda, a classificação correta, que era a medida registrada, difere em poucas seeds e nenhum teste a distingue do acaso, nem no subgrupo registrado (Tabela 12). Também não houve mais mensagens (0,53 [−0,13; 1,27], p ajustado 0,8496). **Na medida registrada, a cognição local não mostrou ganho.**

Tabela 12: RQ7, classificação correta, SMA básico × SMA local (bloco A; família RQ7, p ajustado por Holm; — quando o resultado é idêntico em todos os pares e o teste não se aplica).

Condição	SMA básico	SMA local	Seeds dif.	p ajust.
perda de 5%	75,0%	75,0%	0	—
perda de 15%	72,5%	75,3%	2	1,000
perda de 30%	69,8%	73,7%	2	1,000
combinadas	78,6%	79,5%	2	1,000
subgrupo registrado (desvio irregular com pista, sob perda; 6 seeds)	30,6%	41,7%	1	1,000

Numa medida que não estava designada para RQ7 (execução correta), o braço local fica acima do básico em todas as condições de falha de comunicação (Tabela 13). É exploratório: calculado depois de ver os dados, fora de qualquer família de testes, sobre um braço cujo conteúdo mudou depois do pré-registro, e nenhuma diferença é significativa nem antes de corrigir. O sinal é consistente no sentido e pequeno; o experimento não tem poder para afirmá-lo, e mesmo com ele o braço local fica muito abaixo do workflow equivalente sob perda.

Tabela 13: Exploratório: execução correta, SMA local menos SMA básico (bloco A; p de Wilcoxon sem correção; recalculado de `execucoes.csv`).

Condição	SMA básico	SMA local	Diferença [IC 95%]	Seeds dif.	p
perda de 5%	94,2%	97,5%	+3,3 pp [0,0; 8,3]	2	0,500
perda de 15%	64,2%	72,9%	+8,8 pp [0,4; 18,3]	6	0,0625
perda de 30%	35,0%	42,9%	+7,9 pp [1,7; 16,3]	4	0,125
indisponibilidade	97,1%	98,3%	+1,3 pp [0,0; 3,8]	1	1,000
combinadas	50,8%	57,9%	+7,1 pp [−0,4; 16,7]	5	0,125

Ablação. Base: SMA local com tudo ligado, porte médio, desvio irregular sempre plantado e, no fechamento, um segundo pedido do mesmo mês dois ticks depois (Tabela 14, Figura 4). Três mecanismos têm contribuição clara. O **reenvio** do Orquestrador é o mecanismo de recuperação que funciona (na primeira rodada, antes da correção, não se distinguia do acaso, porque não cobria a resposta perdida). A **reserva de período** é a única coisa que impede dois fechamentos do mesmo mês: sem ela, os dois foram publicados em todas as seeds. O **veto com correção**: sem ele, o aprovador diligente concede waiver e o cauteloso bloqueia, e a publicação cai para 66,7%. A **negociação de prazo** não mostrou efeito na medida designada, e a **cognição local** aponta no sentido esperado sem significância.

Tabela 14: Ablação (bloco C): um mecanismo desligado por vez, na medida designada; p ajustado por Holm na família da ablação.

Mecanismo desligado	Medida designada	Com	Sem	Seeds dif.	p ajust.
reenvio do Orquestrador	execução correta, perda de 15%	63,3%	31,7%	13	< 0,001
reserva de período	publicações do mesmo mês (certo: 1)	1,00	2,00	30	< 0,001
veto com correção	críticas corrigidas por fechamento	2,00	0,00	30	< 0,001
negociação de prazo	classificação correta, consulta instável	50,0%	50,0%	0	—
cognição local	classificação correta, consulta instável	50,0%	40,0%	3	0,250

10.4 Três rodadas

O experimento rodou três vezes, e as três contam. A primeira (commit `cfa6b6f`, CSV `c5a4e032...`) mediu a v0.5.0 como estava e revelou o defeito da resposta perdida. A segunda (commit `174e7b6`, CSV `b21fd5d8...`) mediu o sistema com o barramento corrigido e o acesso avançado integrado; entre as duas mudaram três coisas, não uma: a correção (com ajustes no verificador), o lugar do sorteio do atraso de entrega e o conteúdo do braço local. A terceira (commit `45e545b`, CSV `9d5126a6...`) mede a versão 1.0.0, depois da correção simulada da DSM4: transporte que não apaga a marca da perda e reentrega os avisos de decisão humana (C1, C2; fechamentos de duas seeds passaram de falha explícita a resultado certo sob perda), bloco D com duas pessoas no roteiro de aprovação (com uma só, a dupla aprovação recusava e o bloco D media a

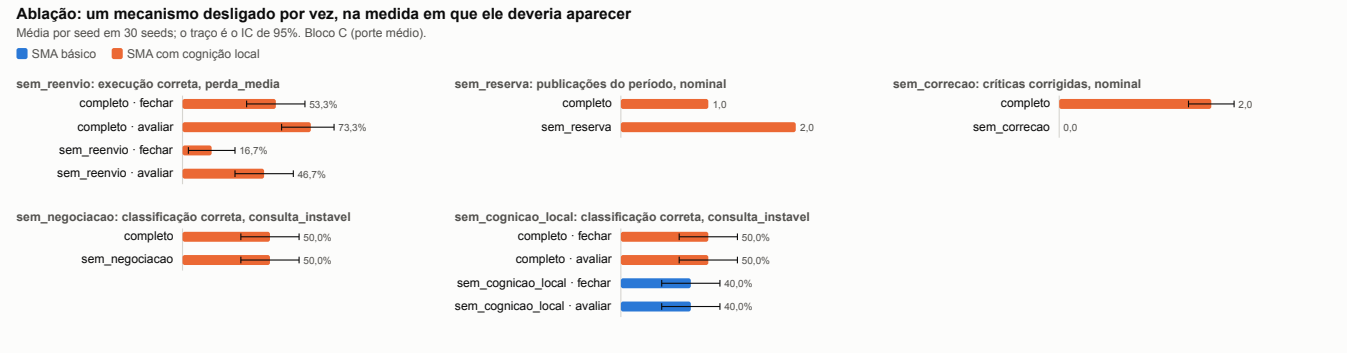


Figura 4: Ablação: cada mecanismo desligado contra o sistema completo.

falta da segunda pessoa; M2) e RQ4 com a seed como unidade (M9). **As correções foram feitas depois de ver resultados, logo nenhuma rodada posterior à primeira é teste confirmatório** das hipóteses de robustez e recuperação: o sistema mudou justamente onde os resultados mostraram que falhava. Como teste, vale o que as três têm em comum.

Tabela 15: As três rodadas lado a lado (SMA básico, salvo indicação).

Medida	1.ª rodada	2.ª rodada	3.ª (final)	Workflow
pares diferentes do workflow, sem falhas (RQ1)	0 de 240	0 de 240	0 de 240	—
execução correta, perda de 5%	80,0%	94,2%	94,2%	100%
execução correta, perda de 15%	48,8%	62,5%	64,2%	100%
execução correta, perda de 30%	22,5%	32,5%	35,0%	100%
execução correta, indisponibilidade	92,1%	97,1%	97,1%	100%
execução correta, humano lento	75,8%	75,8%	75,8%	75,8%
execução correta, combinadas	45,4%	50,8%	50,8%	75,8%
resposta explícita, perda de 5 / 15 / 30%	88,8% / 73,8% / 52,9%	100% nas três	100% nas três	100%
execuções do SMA com invariante violado	807 de 6.480 (INV-07)	0 de 6.480	0 de 6.480	não se aplica
mensagens de coordenação, sem falhas	15,75	15,75	15,75	0,88
latência sem falhas (ticks)	15,9	15,9	15,9	12,7
latência, combinadas (ticks)	43,7 (28 seeds com resposta)	49,2	49,2	18,1
críticas publicadas sem tratamento (SMA)	0	0	0	0
ataques aceitos indevidamente	0 de 1.735	0 de 2.227	0 de 2.227	não atacado
aceitos sem a premissa (bloco D)	8	4	4	não atacado
execução correta, bloco D com ataques	50,0%	56,7%	55,0%	—
ablação do reenvio, perda de 15% (com × sem)	40,0% × 28,3% (p 0,1875)	61,7% × 31,7% (p < 0,001)	63,3% × 31,7% (p < 0,001)	—
RQ4, recuperação local × básico (p ajustado; unidade)	p 0,6047 (execuções)	p 0,0314 (execuções)	p 0,2642 (seeds)	—

O que as correções mudaram: toda solicitação passou a ter resposta; a robustez do SMA subiu em todas as condições de falha de comunicação; o reenvio passou a ter efeito; com 5% de perda, a diferença para o workflow deixou de ser significativa; e a diferença de recuperação entre o braço local e o básico, que parecia significativa com a execução como unidade, deixou de ser. O que não mudou, e por isso não depende das correções: **o empate de qualidade, o custo maior em mensagens, a robustez menor que a do workflow a partir de 15% de perda, zero ataque aceito indevidamente e zero crítica publicada sem tratamento**. A latência sob falha ficou maior que na primeira, porque as execuções que antes travavam agora esperam o prazo, reenviam e entram na média.

10.5 Comportamento coletivo observado

Onde a distribuição custou: cada decisão local precisa de uma troca para ser conhecida pelos outros (mensagens); cada troca pode se perder (exposição); recuperar leva de duas a quatro vezes uma solicitação inteira sem falha; e um reenvio por subtarefa é pouco quando a perda é alta (139 de 240 execuções do SMA básico com 30% de perda terminam em falha explícita). Onde a distribuição ajudou: em nada que este experimento meça como resultado quando as funções são iguais. Na contenção, com uma ressalva: no bloco A, os ataques vindos de identidades falsas, de agentes legítimos fora do papel e

da caixa do aprovador sem a pessoa certa foram todos rejeitados com o sistema degradado e nenhum mudou o desfecho; no bloco D, nenhum foi aceito indevidamente, mas 4 foram aceitos sem a premissa do ataque e o efeito sobre o desfecho não foi testado (Seção 10.3). A contenção depende de cada agente ter papel, credencial e lista de ferramentas próprios, coisa que o controlador único não tem para ser atacada do mesmo modo. Na concorrência, a reserva de período, um mecanismo de coordenação, foi o que impediu a dupla publicação. O que as falhas não quebraram: nenhuma crítica publicada sem tratamento nas 6.480 execuções do SMA, em nenhuma rodada, e nenhum invariante violado na segunda e na terceira.

10.6 O que não se confirmou

1. H7b e H7c: a cognição local não melhora a classificação de forma distinguível do acaso nem custa mais mensagens.
2. H2a para 5% de perda e para a indisponibilidade de um especialista: sinal previsto, sem significância.
3. H4a para 30% de perda e para as falhas combinadas: a maioria das atingidas não recupera o resultado.
4. H5b para o limiar de 5% (nenhum efeito), o de 20% (não significativo após Holm), o prazo de aprovação e o TTL da reserva (não significativos).
5. H3b na parte da auditoria: o trace quase não cresce com o controle de acesso.
6. H3a na latência sem falhas, fora da premissa: com 4 ticks por etapa no workflow, o SMA deixa de ser mais lento.
7. Ablação da negociação de prazo e da cognição local: contribuição não distinguível do acaso.
8. A expectativa de zero violações, na primeira rodada: 807 execuções violaram o INV-07.

O que não foi testado: H6b com o controle de acesso ligado; latência real entre os braços; "sempre responde" fora dos parâmetros (atraso acima de 6 ticks, agente fora do ar além das cinco tentativas da reentrega, rajadas e partição); um workflow distribuído; MEI, Média empresa II, aprovador rigoroso e Orquestrador que cai.

10.7 Desvios do pré-registro

O pré-registro dizia que o defeito previsto seria medido, não corrigido; ele foi corrigido, e depois os dois defeitos restantes do transporte, e o experimento rodou de novo a cada vez. Na terceira rodada, o bloco D ganhou a segunda pessoa do roteiro de aprovação (a dupla aprovação entrou depois do pré-registro) e os testes da RQ4 passaram a usar a seed como unidade (o pré-registro descrevia "grupos de execuções"); a regra de deixar comparações idênticas fora do Holm foi aplicada depois da primeira execução. O defeito era mais amplo que o previsto (estava também no PROT-DEL e respondia pela maior parte das execuções sem resposta). O braço local mudou de conteúdo. O sorteio do atraso mudou de lugar. MEI e Média empresa II, que entraram depois, ficaram fora (o workflow equivalente não implementa as regras deles). A métrica de ataques foi desdobrada em bruto e sem a premissa do ataque, depois de ver o primeiro caso numa rodada de teste do aparato. Três medidas são exploratórias (sinalização, execução correta na RQ7 e a latência com outra premissa). Rodadas de fumaça do aparato foram olhadas antes (seeds 1 a 3 e uma configuração que não é condição do experimento); seeds, condições, tamanho da amostra e comparações não mudaram. O bloco de fuzz citado no plano geral não foi feito. A lista completa, com as reexecuções e suas causas, está em `docs/dsm4/resultados.md`.

10.8 Ameaças à validade

Construto. Três resultados saem em boa parte do desenho: a equivalência da RQ1 foi escrita e testada até igualar; a robustez da RQ2 favorece o workflow porque o modelo de falhas só atinge a comunicação entre agentes, e um workflow distribuído (controlador com serviços remotos) não foi construído; e a ordem da H2b vem em parte das perdas aninhadas pelos números aleatórios comuns. O que o SMA compra (separação de autoridade, menor privilégio, trilha de quem decidiu) não aparece em métrica de resultado. Um tick é unidade do relógio lógico, e os 3 ticks por etapa do workflow são premissa que decide o sinal da latência sem falhas. A execução correta compara cada execução com a nominal do mesmo bloco e não serve para comparar blocos. O gabarito de classificação tem teto abaixo de 100% em três situações (desvio orçamentário e irregular na mesma conta; na micro, desvio plantado exatamente no limiar; na micro, duplicidade descontada do desvio), que atingem SMA e workflow por igual. **Interna.** O workflow equivalente foi escrito depois do SMA, pelos mesmos autores, lendo os agentes; a equivalência é testada só sem falhas. A segunda e a terceira rodada foram medidas depois de corrigir o que a anterior mostrou. O pareamento entre SMA e workflow é parcial: os braços trocam mensagens diferentes. **Externa.** Dados sintéticos com plantio; perda independente por mensagem, sem rajadas nem partição; Orquestrador que não cai; um único nível de recuperação (um reenvio), escolha que determina boa parte da distância para o workflow sob perda alta (com três tentativas, 63,3% contra 51,7% nas combinadas). **Conclusão.** Como a perda é sorteada por mensagem com chave comum, as oito células de uma seed compartilham o destino das mensagens: o efeito aparece em poucas seeds inteiras e as comparações com 5% de perda, prazo de aprovação, TTL, cognição e negociação não têm poder para dar significativas. Holm controla o erro por família, não no experimento inteiro. A amostra não teve aprovador rigoroso (probabilidade 0,10; não saiu nas 30 seeds).

11. Limitações

A lista completa e sem suavização está em `docs/dsm4/limitacoes.md`. As que mais pesam:

- **O SMA não ganha do workflow equivalente em nenhuma métrica de resultado**, e perde em custo e em robustez sob perda de mensagens. A recuperação é um reenvio por subtarefa.
- **Raiz de confiança no processo e no disco**: credenciais em memória do processo; chaves simétricas na pasta de chaves; quem lê essa pasta forja trace, memória ou cadastro válidos. Barramento em processo, sem rede; numa versão distribuída, mTLS ou assinatura por mensagem.
- **Ponto único de falha**: o Orquestrador não cai no experimento nem tem substituto.
- **Cognição**: o pacote local não mostrou ganho; o AG-REL BDI não acrescenta capacidade; as regras locais reconhecem poucas formas de escrever; nenhum LLM real foi avaliado.
- **Pedido sem atestado**: a pessoa do pedido vem da sessão da interface, não de um atestado no PROT-SOL; a resposta final ao solicitante, se perdida, não é avisada.
- **Dados sintéticos**: o gabarito é o que foi plantado; empresas reais têm erros combinados e ambíguos.
- **Interfaces**: TUI não verificada em Windows; expiração de sessão por tempo sem teste automatizado; os roteiros Playwright não foram executados na geração deste relatório; delegações, empresa ativa, segundo fator e cofre não têm tela no dashboard web.
- **Cofre sem cifra**: integridade e controle de acesso, não confidencialidade contra quem lê o disco.
- **Fontes**: nenhum conector de fornecedor nem ERP real testado; o entendimento de fontes depende de um vocabulário finito de sinônimos, e o que ele não reconhece a pessoa mapeia à mão.
- **Em aberto depois da correção simulada da DSM4**: quem já tem a senha ou uma sessão de outra pessoa pode bloquear o segundo fator ou a troca de senha dela por 15 minutos (troca consciente contra a força bruta); a resposta ao solicitante não menciona “aplicado, confirmação inválida” (fica no trace e no ticket); o AG-CIN e o AG-ORC terminam com intenção aberta em parte das execuções com falha, sem afetar a resposta; nenhum invariante cobre “uma liberação humana por veto”; a reentrega garantida para em cinco tentativas; a TUI não tem campo de segmento no cadastro de empresa. O avaliador não verificou planilha maliciosa, redirecionamento 30x, ERP lento, o wheel instalado, o Docker Compose, provedores reais de LLM nem os roteiros Playwright.

Saíram da lista da DSM3 nesta entrega: o experimento sem variância e desequilibrado, os especialistas só reativos, a resposta perdida que virava silêncio (também com entrega atrasada, C1), o aviso de decisão humana perdido (C2), a senha como único fator e o segundo fator derrubável por força bruta (C3), as fontes compartilhadas entre empresas (C4), a restauração que gravava fora do destino (C5), o aprovador sem limite de valor e sem substituto, a memória que perdia entradas entre processos e o cadastro de uma empresa só.

12. Conclusão

Para este problema e este tamanho, um controlador centralizado com as mesmas regras entrega a mesma qualidade, com menos mensagens e sem a exposição à perda de mensagens. O SMA não se justifica pelo resultado medido, e o relatório não transforma isso em empate técnico. O que a arquitetura de agentes entrega e o workflow não entrega são propriedades de desenho, verificáveis por teste e por trace, mas não por métricas de resultado: **separação de responsabilidades auditável** (quem calcula não julga conformidade, quem julga não aprova, e cada decisão tem autor no trace); **veto independente** do AG-CIN, que nenhum outro agente consegue contornar; **decisão humana atestada** pela pessoa autenticada, com cargo e segregação de funções conferidos; **negociação** explícita de prazo entre quem executa e quem coordena; e **extensibilidade** (um especialista novo entra com papel, protocolos e allowlist próprios, sem tocar nos demais). O experimento mostrou que essas garantias se mantêm com o sistema degradado (zero crítica publicada sem tratamento, zero ataque aceito indevidamente) e mostrou também onde a distribuição custa. Os trabalhos seguintes que os dados indicam são uma recuperação mais forte que um reenvio, um workflow distribuído como linha de base justa para robustez e a medição de um modelo real na bancada de hipóteses, fora do experimento principal.

A. Grafos de rastreabilidade por parte

Gerados de `models/*.yaml` por `tools/relatorio_numeros.py` (as mesmas cadeias que o `tools/trace.py --check` valida e que a documentação navegável mostra por `needflow`). O número de testes é o de testes modelados que verificam o requisito.

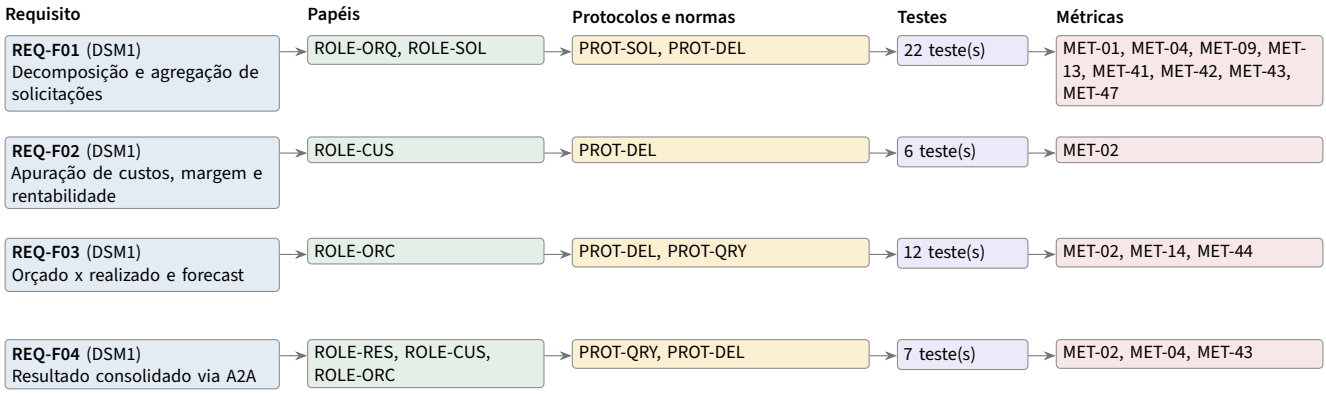


Figura 5: Rastreabilidade, funcional: REQ-F01 a REQ-F04. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

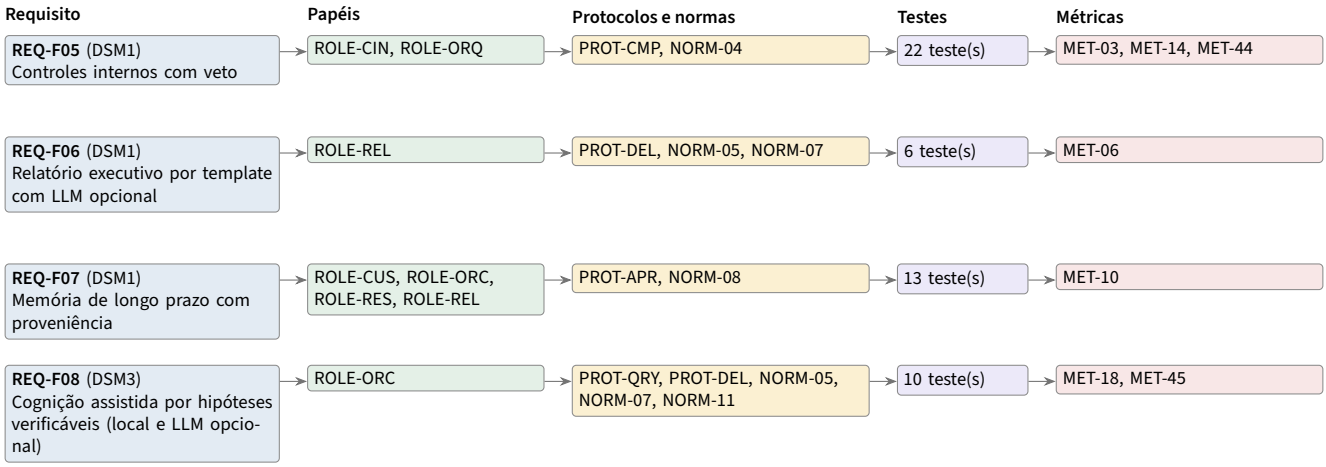


Figura 6: Rastreabilidade, funcional: REQ-F05 a REQ-F08. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

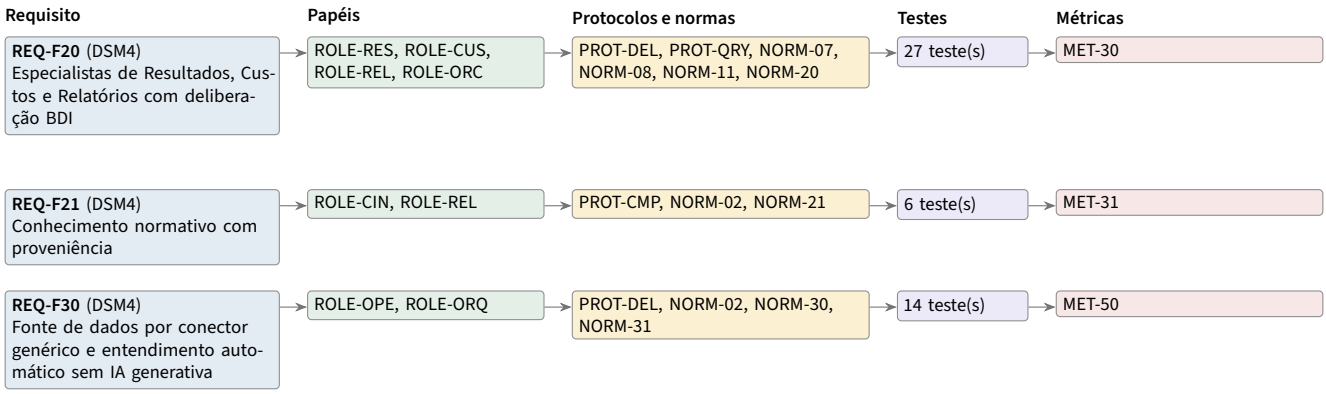


Figura 7: Rastreabilidade, funcional: REQ-F20 a REQ-F30. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

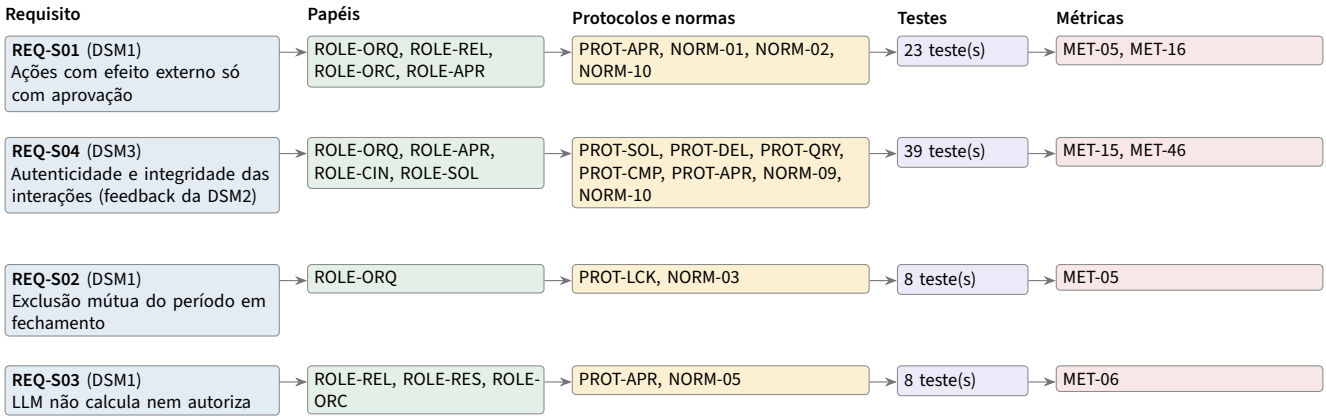


Figura 8: Rastreabilidade, segurança: REQ-S01 a REQ-S03. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

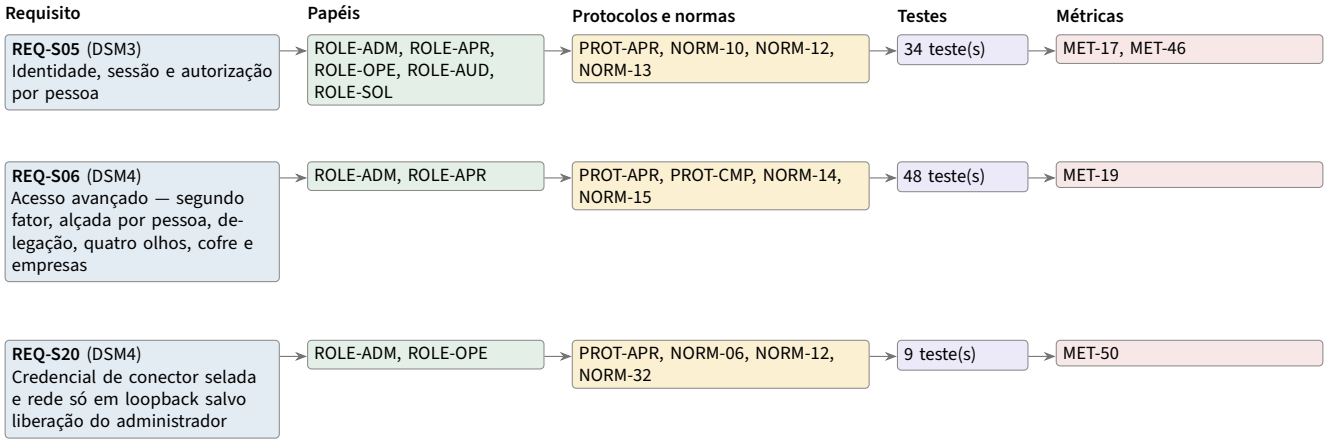


Figura 9: Rastreabilidade, segurança: REQ-S05 a REQ-S20. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

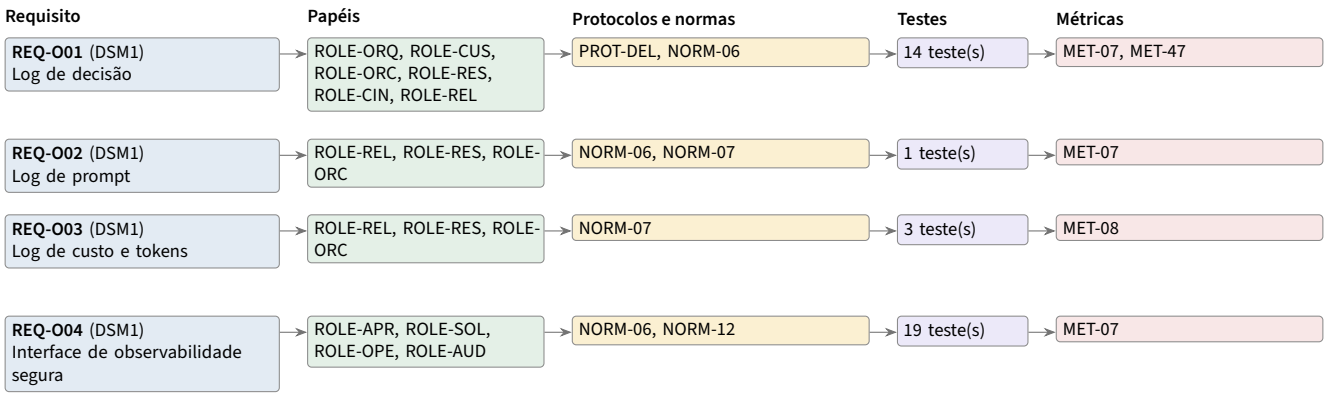


Figura 10: Rastreabilidade, observabilidade: REQ-O01 a REQ-O04. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

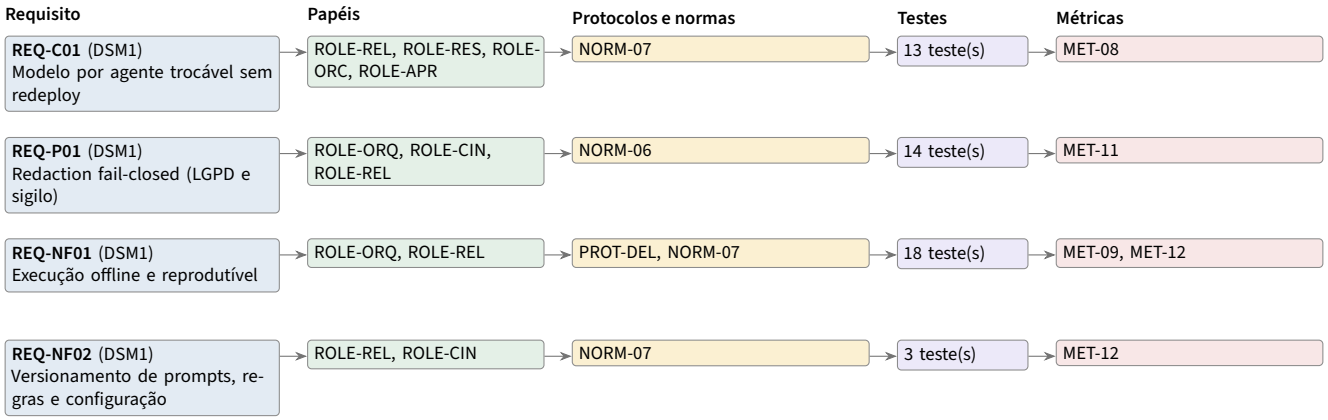


Figura 11: Rastreabilidade, demais requisitos: REQ-C01 a REQ-NF02. Cadeia requisito → papéis → protocolos e normas → testes → métricas, lida de `models/*.yaml`.

Referências

BNDES (2026). *Porte de empresa*. URL: https://www.bndes.gov.br/wps/portal/site/home/financiamento/guia/porte-de-empresa (acesso em 12/11/2026).

Brasil (2006). *Lei Complementar n.º 123, de 14 de dezembro de 2006 (Estatuto da Microempresa e da Empresa de Pequeno Porte)*. Art. 3.º e art. 18-A, com a redação da LC 155/2016 e da LC 188/2021.

Bratman, Michael E. (1987). *Intention, Plans, and Practical Reason*. Cambridge, MA: Harvard University Press.

Bresciani, Paolo et al. (2004). "Tropos: An Agent-Oriented Software Development Methodology". Em: *Autonomous Agents and Multi-Agent Systems* 8.3, pp. 203–236.

Cancian, Rafael Luiz (2026). *Sistemas Multiagentes Inteligentes*. Material didático da disciplina INE5628, versão rascunho 0.26.09; capítulos 3 a 5 consultados. Universidade Federal de Santa Catarina. Florianópolis.

Cliff, Norman (1993). "Dominance Statistics: Ordinal Analyses to Answer Ordinal Questions". Em: *Psychological Bulletin* 114.3, pp. 494–509.

Efron, Bradley e Robert J. Tibshirani (1993). *An Introduction to the Bootstrap*. New York: Chapman & Hall.

FIPA (2002a). *FIPA ACL Message Structure Specification*. SC00061G. Foundation for Intelligent Physical Agents.

FIPA (2002b). *FIPA Request Interaction Protocol Specification*. SC00026H. Foundation for Intelligent Physical Agents.

Holm, Sture (1979). "A Simple Sequentially Rejective Multiple Test Procedure". Em: *Scandinavian Journal of Statistics* 6.2, pp. 65–70.

Kinny, David e Michael Georgeff (1991). "Commitment and Effectiveness of Situated Agents". Em: *Proceedings of the 12th International Joint Conference on Artificial Intelligence (IJCAI-91)*, pp. 82–88.

Mann, Henry B. e Donald R. Whitney (1947). "On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other". Em: *The Annals of Mathematical Statistics* 18.1, pp. 50–60.

Nosek, Brian A. et al. (2018). "The Preregistration Revolution". Em: *Proceedings of the National Academy of Sciences* 115.11, pp. 2600–2606.

Padgham, Lin e Michael Winikoff (2004). *Developing Intelligent Agent Systems: A Practical Guide*. Chichester: John Wiley & Sons.

Rao, Anand S. e Michael P. Georgeff (1991). "Modeling Rational Agents within a BDI-Architecture". Em: *Proceedings of the Second International Conference on Principles of Knowledge Representation and Reasoning (KR'91)*, pp. 473–484.

Rao, Anand S. e Michael P. Georgeff (1995). "BDI Agents: From Theory to Practice". Em: *Proceedings of the First International Conference on Multi-Agent Systems (ICMAS-95)*, pp. 312–319.

Robertson, Stephen e Hugo Zaragoza (2009). "The Probabilistic Relevance Framework: BM25 and Beyond". Em: *Foundations and Trends in Information Retrieval* 3.4, pp. 333–389.

Romano, Jeanine et al. (2006). "Appropriate Statistics for Ordinal Level Data: Should We Really Be Using t-test and Cohen's d for Evaluating Group Differences on the NSSE and Other Surveys?" Em: *Annual Meeting of the Florida Association of Institutional Research*.

Smith, Reid G. (1980). "The Contract Net Protocol: High-Level Communication and Control in a Distributed Problem Solver". Em: *IEEE Transactions on Computers* C-29.12, pp. 1104–1113.

Wilcoxon, Frank (1945). "Individual Comparisons by Ranking Methods". Em: *Biometrics Bulletin* 1.6, pp. 80–83.

Wooldridge, Michael (2009). *An Introduction to MultiAgent Systems*. 2ª ed. Chichester: John Wiley & Sons.

Wooldridge, Michael, Nicholas R. Jennings e David Kinny (2000). "The Gaia Methodology for Agent-Oriented Analysis and Design". Em: *Autonomous Agents and Multi-Agent Systems* 3.3, pp. 285–312.